

摘要

森林疗养作为我国绿色可持续发展林业新模式，为广大人民群众带来健康福祉。针对林学会森林疗养分会亟需实现疗养师在线培训需求，同时为数不多的现有系统因课程视频繁杂和检索系统单一均存在不同程度上检索困难问题，导致用户难以高效准确检索到目标课程视频，影响培训质量和效果。文本视频检索（Text to Video Retrieval，简称 T2VR）作为跨模态检索核心任务，能够实现用户通过文本查询准确检索出相关视频目标。本文提出一种基于视频字幕和多空间学习的文本视频检索（Text to Video Retrieval based on Video Captions and Multi-space Learning，简称 TVRVCML）模型，设计构建一个森林疗养课程培训系统，聚焦于在线培训森林疗养师，并提供准确实用课程视频检索服务。本文主要工作如下：

（1）针对仅在单个公共空间中难以同时匹配文本和视频内多种语义信息问题，本文提出 TVRVCML 模型，其包括特征编码、多空间构建和多空间融合三层结构。为构建多个公共空间，首先采用多种不同类型的编码器分别对查询文本、视频和视频字幕进行特征表示。借助跨模态匹配和同模态匹配相结合思路做出改进，一方面构建查询文本与视频之间跨模态公共空间，另一方面构建查询文本与视频字幕之间同模态公共空间。此外，通过在多个公共空间中引入自注意力机制策略，为多空间分配权重，建模不同公共空间关系，以提升 TVRVCML 模型检索能力。

（2）为验证模型性能，本文进行多层次实验设计。首先，在三个基准数据集 MSVD、MSR-VTT 和 TGIF 上与四个先进模型进行对比实验，验证模型设计有效性。同时，在 MSVD 数据集上进行消融实验。此外，构建模型的超参敏感性实验。实验结果证实 TVRVCML 模型在前 K 项召回率、中位数排名等指标上均有明显提升。

（3）针对森林疗养在线培训需求，本文采用Vue和Spring Boot前后端分离的开发模式设计实现一个Web端森林疗养课程培训系统。该系统分为学员端和管理员端，不仅能为学员提供友好、实用的系统培训服务，还能为管理员提供资源管理、课程管理、班课管理和学员管理等功能模块。同时，通过将TVRVCML模型应用于本系统的课程视频检索功能，以缓解用户检索困难问题，显著提升了培训质量和效果。目前该系统已交付使用，系统运行流畅稳定，为森林疗养在线培训提供有力支撑。

关键词：森林疗养，课程培训系统，文本视频检索，多空间学习

Research and Construction of Forest Recuperation Course Training System Fused Text to Video Cross Modal Retrieval

Master Candidate: Yang Guo Xing

(Software Engineering)

Directed by Tian Xuan and Cao Yao Zhu

Abstract

Forest recuperation, as a new pattern of green and sustainable forestry development in China, brings health and well-being to the public. The Forest Recuperation Branch of the Forestry Society urgently needs to meet the online training needs of therapists. At the same time, the few existing systems have varying degrees of retrieval difficulties due to the complexity of course videos and the single retrieval system, which makes it difficult for users to retrieve target course videos efficiently and accurately, affecting the quality and effectiveness of training. Text to Video Retrieval (T2VR), as a core task of cross modal retrieval, can enable users to accurately retrieve relevant video targets through text queries. This article proposes a Text to Video Retrieval based on Video Captions and Multi space Learning (TVRVCML) model and designs and constructs a forest therapy course training system that focuses on online training of forest therapists and provides accurate and practical course video retrieval services. The main work of this article is as follows:

(1) In response to the difficulty of matching multiple semantic information within text and video in a single public space, this paper proposes a TVRVCML model, which includes a three-layer structure of feature encoding, multi-space construction, and multi-space fusion. To construct multiple public spaces, various types of encoders are first used to represent the features of query text, video, and video subtitles. By combining cross modal matching and same modal matching, improvements are made. On the one hand, a cross modal public space is constructed between query text and video, and on the other hand, a same modal public space is constructed between query text and video subtitles. In addition, by introducing self-attention mechanism strategies in multiple public spaces, weights are assigned to multiple spaces, and different public space relationships are modeled to improve the retrieval ability of the TVRVCML model.

(2) To verify the performance of the model, this article conducts a multi-level experimental design. Firstly, comparative experiments were conducted with four advanced models on three benchmark datasets, MSVD, MSR-VTT, and TGIF, to verify the effectiveness of the model design. Meanwhile, ablation experiments were conducted on the MSVD dataset. In addition, hyperparametric sensitivity experiments were conducted to construct the model. The experimental results confirm that the TVRVCML model has significantly improved in the top K recall rate, median ranking, and other indicators.

(3) In response to the demand for online forest therapy training, this article adopts the development mode of front-end and back-end separation of Vue and Spring Boot to design and implement a web-based forest therapy course training system. The system is divided into a student end and an administrator end, which not only provides friendly and practical system training services for students, but also provides functional modules such as resource management, course management, class management, and student management for administrators. At the same time, by applying the TVRVCML model to the course video retrieval function of this system, the problem of user retrieval difficulties is alleviated, significantly improving the quality and effectiveness of training. At present, the system has been delivered for use and runs smoothly and stably, providing strong support for online training of forest recuperation.

Key Words: Forest recuperation, course training system, text to video retrieval, multi-space learning

目录

1 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 在线课程培训系统研究现状	2
1.2.2 文本视频检索算法研究现状	3
1.3 研究内容及技术路线	5
1.4 论文组织结构	7
2 文本视频检索相关技术介绍	8
2.1 文本特征表示技术	8
2.1.1 词袋模型	8
2.1.2 词向量模型	9
2.1.3 深度神经网络模型	10
2.2 视频特征表示技术	14
2.2.1 帧级特征聚合为视频级特征	14
2.2.2 多种专家特征融合	15
2.3 公共空间学习技术	16
2.4 本章小节	17
3 基于视频字幕和多空间学习的文本视频检索	18
3.1 引言	18
3.2 模型结构设计	19
3.2.1 模型整体结构	19
3.2.2 特征编码层	21
3.2.3 多空间构建层	23
3.2.4 多空间融合层	24
3.3 实验条件与环境设置	25
3.3.1 数据集描述	25
3.3.2 评价指标	26
3.3.3 实验运行环境	27
3.3.4 模型参数设置	27
3.4 实验构建与结果分析	28
3.4.1 基线模型选取	28
3.4.2 对比实验分析	29
3.4.3 消融实验分析	32

3.4.4 超参敏感性实验分析	33
3.5 本章小节	34
4 森林疗养课程培训系统研建	35
4.1 系统需求分析	35
4.1.1 功能性需求	35
4.1.2 非功能性需求	37
4.2 系统概要设计	38
4.2.1 系统架构设计	38
4.2.2 系统功能模块设计	40
4.2.3 数据库设计	42
4.3 系统详细设计与实现	48
4.3.1 资源管理模块详细设计与实现	48
4.3.2 课程管理模块详细设计与实现	51
4.3.3 班课管理模块详细设计与实现	52
4.3.4 学员学习模块详细设计与实现	54
4.4 系统测试	56
4.4.1 功能测试	56
4.4.2 非功能测试	58
4.5 本章小节	59
5 总结与展望	60
5.1 总结	60
5.2 展望	61
参考文献	62
导师简历	65
校外导师简历	66
个人简历	67
获得成果目录清单	68
致谢	69

1 绪论

1.1 研究背景及意义

近年来,我国高度重视生态文明建设,致力于推进健康中国进程。同时,“双碳”战略的实施为森林赋予更加深远新内涵。森林疗养作为绿色可持续发展的林业新模式,不仅为广大人民群众带来健康福祉,同时促进人与自然和谐共生理念^[1]。森林疗养师作为国内一种新兴职业,在森林疗养过程中扮演重要角色。他们引领参与者融入各种丰富多彩的森林活动,一方面提供专业且细致指导,另一方面帮助参与者舒缓生活和工作压力,营造出更为优质和舒适的疗养氛围以深化与自然的连接。为培养专业森林疗养师,迫切需要在线课程培训系统以适应行业发展要求。这不仅能够打破传统培训时空限制,更能提升疗养师专业技能和知识水平,推动森林疗养行业持续发展。

然而,由于森林疗养师这一新兴职业在我国处于起步阶段,专门用于培养疗养师的在线课程培训系统相对匮乏。同时,为数不多的现有系统因课程视频繁杂以及检索系统存在局限性,常常导致用户难以高效准确检索到目标课程视频,影响培训质量和效果。因此,研建一个高效实用的课程培训系统具有重要现实意义。

随着移动互联网、智能设备和社交媒体飞速发展,互联网中各种数据处于指数级增长状态。特别是对于一些用户生成内容(User Generated Content,简称UGC)平台,如国内的抖音、快手、哔哩哔哩以及国外的YouTube和TikTok等视频平台,在这些平台上每天都会新增上亿级视频数据。如何从海量视频数据中高效而准确检索出目标视频已成为一个亟需解决的关键研究问题。在此背景下,T2VR作为自然语言处理和计算机视觉交叉领域的一项核心任务,受到了广泛关注。其旨在构建和计算查询文本与视频之间语义相似度,以实现跨模态数据的检索和对应^[2]。随着深度学习技术进步,目前广泛采用基于公共空间学习的方法,按照算法流程可以分为三个主要步骤:特征表示、特征匹配和相似度计算。T2VR技术的重要意义在于其显著提升了信息检索准确度和效率,并在许多领域具有广泛应用价值,如在线教育、公共安全、媒体管理和电商零售等领域。

本文针对林学会森林疗养分会亟需实现疗养师在线培训需求,设计实现一个森林疗养课程培训系统。本系统致力于为参与培训的学员用户提供实用而友好的在线课程培训体验,促进对培训内容深入理解和学习。与此同时,为系统管理员提供资源管理、课程管理、班课管理和学员管理等一系列功能,提高管理效率。此外,通过将TVRVCML模型应用于课程视频检索业务中,为用户提供高效而实用检索体验。借助本系统发挥在线课程培训优势并结合文本视频检索算法,不仅能提高疗养师培训效果和质量,还有助于森林疗养行业持续发展,推进生态文明建设进程。

1.2 国内外研究现状

1.2.1 在线课程培训系统研究现状

近年来,在线课程培训系统呈现出快速发展趋势,成为人们获取知识和技能重要途径之一。与此同时,森林疗养^[3]在全球范围内广受青睐,开始成为当前社会热点领域。为培养专业森林疗养师,发挥线上线下相结合的培训优势,其相关课程培训系统逐渐引发关注。本节将以国内外目前常用在线课程培训系统和森林疗养课程培训系统为例,分别阐述两者研究现状。

(1) 在线课程培训系统研究现状

① 中国大学 MOOC

慕课(MOOC)全称为大规模开放式在线课程,是一种借助互联网向学习者提供免费或收费课程的在线教育模式。中国大学 MOOC^[4]是由网易与高等教育出版社携手推出的在线课程网站,在国内具有较大影响力。该网站主要提供教育部国家精品课程,包含国内一系列知名高校。然而,这类专门服务于高校教育的在线课程网站,往往侧重于主流学科和热门领域,森林疗养这类公众认知度较低的课程相对稀缺。

② 学堂在线

学堂在线^[5]由清华大学于 2013 年自主建设运营,是中国首个慕课平台。针对教学过程中最常用的微信和 PPT 两款软件,还推出智慧教学工具雨课堂^[6]。经过多年发展,该平台汇集了众多优质在线课程资源,涵盖计算机、经济学、文学文化、医学卫生和教育教学等多个学科。然而,同样存在平台上仅有热门学科课程问题,导致希望学习森林疗养等特定领域的学习者无法获取相关在线课程信息。

③ Coursera

Coursera^[7]是一家美国在线教育平台,与全球知名高校和培训机构合作。它提供了大量在线课程资源,涵盖人文、社会科学、理工科和商科等多个领域。面对众多课程信息,该平台为用户提供四个核心类型:个人课程、商业课程、大学课程和政府课程。但仅靠核心分类和简单搜索条件,用户寻找目标课程成本依旧较高。另外,该平台仍然存在只有大众需求更广泛领域相关课程的情况,对森林疗养等小众领域相关课程的重视度不足。

(2) 森林疗养课程培训系统研究现状

① 森林疗养师在线培训系统

森林疗养师在线培训系统(www.foresttherapy.cn)由北京市园林绿化局开发,其培训内容包括了森林疗养概论、康复景观学和环境心理学等多门课程。然而,该系统页面存在平铺式展示问题。这种将所有课程集中在一起的方式,导致信息繁多和混乱,且在检索条件单一情况下,对于不清楚课程名称或类型的用户来说,要快速准确定位目标课程视频并不容易。

② ANFT

美国森林疗养协会（ANFT）成立于 2008 年，致力于推广森林疗养^[3]。该协会提供森林疗养在线培训平台，旨在培养有能力引导他人在自然环境中进行疗愈性体验的森林疗养师，培训课程包括森林疗养理论、实践和指导技巧等。由于该系统中课程视频数量庞大且类型多样，导致用户在检索目标视频时面临诸多困难。此外，该系统同样存在检索功能单一问题，进一步增加了用户寻找目标视频难度。

综上所述，在线课程培训系统作为综合性平台，其课程内容主要面向教育、医疗、经济和科技等热门领域。由于森林疗养应用范围相对有限，主要集中在特定人群或场景中，导致在这些综合性系统中难以找到相关课程。另外，为数不多的森林疗养课程培训系统均存在不同程度检索困难问题，面对在线平台中繁多课程视频，用户无法通过自然语言描述的文本查询条件快速准确找到目标视频。

1.2.2 文本视频检索算法研究现状

随着互联网普及和在线视频平台快速发展，大量文本和视频数据不断产生。面对爆炸式增长的多模态信息，人们迫切需要找到有效途径来检索目标内容，在此背景下，T2VR 任务应运而生。其旨在通过用户输入文本查询，在无标记视频数据库中跨模态检索出与查询文本语义相关的视频。T2VR 任务经过近十年发展，研究趋势可以概括为从浅层模型方法逐渐向深层模型方法的转变，具体可以分为基于概念的方法、基于单个公共空间的方法、基于多个公共空间的方法和基于视频字幕的方法。下面将从这四个方法对 T2VR 任务研究现状展开详细阐述。

（1）基于概念的方法

早期 T2VR 研究主要遵循基于概念的方法，即通过预设概念构建查询文本和视频特征表示，依赖于视觉概念分类器描述视频内容和语言规则检测文本概念来描述文本内容。然后借助概念匹配来计算查询文本和视频相似度。例如，提出一种基于文本的解决方案，每个视频都使用预训练的卷积神经网络（Convolutional Neural Network，简称 CNN）从视频中提取视觉概念进行注释，随后通过匹配查询文本和视频注释来计算查询文本和视频之间相似性。同样，Ueki 等人^[8]采取类似思路，提出一个更大的概念库，由超过 5 万个概念组成。在使用预训练的 CNN 模型基础上，还使用 SVM 分离器来注释视频内容。同时，Markatopoulou 等人^[9]提出一种基于规则的概念选择方法，通过计算查询文本和视觉概念之间的语义相似度得分。如果分数高于给定阈值，则选择概念并将其用于表示文本查询。反之，执行多步语言分析以选择匹配文本查询的视觉概念。除了重点关注查询文本概念外，Snoek 等人^[10]提出一种称为 VideoStory^[11] 的表示技术。对于每个未标记视频，将其 CNN 特征通过线性变换转化为所谓的 VideoStory 嵌入。然后，通过另一个线性变换将视频嵌入转换为词袋向量，从而将查询文本和视频之间的相似性转换为词袋向量之间的余弦相似性。

对于早期 T2VR 研究中基于概念的方法而言,随着视频数量和内容增长,难以使用一些既定概念来描述视频和文本查询之间丰富且复杂的内容。尽管如此,基于概念的方法为后续 T2VR 发展奠定了基础,且具有可解释性强、检索结果准确度高等优势,在深度学习时代仍然受到一定程度关注。

(2) 基于单个公共空间的方法

随着深度学习在自然语言处理和计算机视觉领域取得巨大成功,借助深度神经网络强大的编码和学习能力, T2VR 任务全面进入深度学习时代。在此期间,基于单个公共空间的方法在 T2VR 任务中得到广泛应用。按照算法流程,该方法可以分为特征表示、特征匹配和相似度计算三个主要步骤。首先,利用深度神经网络强大编码能力对视频和文本数据进行向量化特征编码。其次,将查询文本和视频向量映射到公共空间中以进行特征匹配,并选取距离函数计算模态相似度。最后,设计损失函数,优化特征向量间距离。例如, Li 等人^[12]提出一种词到视觉向量 (Word2VisualVec, 简称 W2VV++) 模型,它通过将多个文本特征向量的输出连接到一个长特征向量中来组合多种句子编码器,然后利用全连接层将连接向量映射到一个公共空间中。Gabeur 等人^[13]提出多模态 Transformer (Multi-modal Transformer, 简称 MMT) 模型以融合多模态特征,通过多种视频编码器提取特定视频模态后,通过特征融合获得最终视频特征向量,并将其与文本特征向量输入到公共空间中以计算模态相似度。在 MMT 模型基础上, Wu 等人^[14]通过添加自注意力机制和多任务学习策略,丰富视频特征表示,以在公共空间中达到更好的特征匹配效果。上述方法在 T2VR 任务中取得了良好性能,是深度学习技术在 T2VR 任务中优秀示范。

然而,由于查询文本和视频都具有丰富的语义信息,比如,文本中动词、名词和语气词以及视频中画面、字幕、动作和音频等。导致仅在单个公共空间中同时匹配多种不同的文本和视频语义信息有较大困难,存在一定的局限性和偏差。

(3) 基于多个公共空间的方法

近期,越来越多的研究工作开始采用多个公共空间学习^[21]的方法来处理特征匹配和相似度计算,而非仅使用一个公共空间。构建多空间的方法可以大致分为两类:基于单个编码器的方法和基于多个编码器的方法。首先,前者通常采取对视频或文本进行特征拆分的方法来构建多个公共空间。例如, Mithun 等人^[15]将视频分为画面特征和非画面特征(如动作、音频等),分别构建视频画面特征与文本特征间公共空间和视频非画面特征与文本特征间公共空间,以双空间学习计算最终的模态相似度。Miech 等人^[16]利用四种不同特征,即,外观、运动、面部和音频特征来表示视频,并为每种视频特征学习一个公共空间。最终相似度为所有公共空间中相似度之和。类似地, Wray 等人^[17]将文本分解为名词和非名词词,并分别投影到两个不同的公共空间中。Chen 等人^[18]将文本分解为事件,动作和实体,并构建三个公共空间用于视频-文本匹配。同时,通过多种编码器构建多个公共空间,例如, Li 等人^[19]提出一种端到端

的文本编码器组合 SEA 框架,采用多种文本编码器组合,如 BoW、Word2Vec、GRU、BERT 等,通过多种文本特征向量来构建多空间以计算相似度。Dong 等人^[20]则提出一种混合空间学习方法,该方法同时构建语义空间和概念空间,结合两种公共空间用于特征匹配和相似度计算。受人类阅读策略启发,Dong 等人^[21]提出一种新颖的双分支模型用于视频特征表示。其中,预览分支用于获取视频全局特征信息,精度分支则用于获取更深入的局部特征信息,并分别构建多空间以进行模态匹配和相似度计算。

相较于基于单个公共空间方法而言,上述方法在处理查询文本和视频丰富语义信息时,能够实现更加精确的模态匹配。然而,以上大部分工作仅关注构建文本特征向量与视频特征向量之间的多个跨模态公共空间,忽略了对文本和视频之间同模态信息的挖掘,容易引发信息丢失问题,导致无法有效利用文本和视频之间的潜在关联。

(4) 基于视频字幕的方法

对于 T2VR 任务来说,与其他跨模态检索任务相同,最大的挑战在于如何衡量多模态数据之间相似性。由于视频本身包含描述文本、图片、音频等多种模态数据,其中也涉及到视频字幕与用户查询文本之间的同模态关系。本文注意到在 T2VR 任务中,部分研究工作在特征表示阶段,通过将视频字幕等文本信息与视频信息进行联合特征表示,在提高检索性能方面取得出人意料的效果。例如,Dong 等人^[22]提出一种深度神经网络 Word2VisualVec 模型,通过将描述图像或视频内容的字幕文本一并映射到视觉特征空间中进行训练,挖掘同模态信息之间关联,提高了模型在预测阶段的检索表现。另外,Wu 等人^[23]提出一种 Cap4Video 框架,通过为视频生成字幕,并在特征表示阶段增加视频字幕与查询文本之间联合训练分支,减小视频与查询文本间跨模态语义差距,同样获得良好检索效果。

与现有工作主要关注特征表示阶段不同,本文以模态匹配阶段为研究重心。在构建多个跨模态公共空间基础上,同时构建视频字幕和查询文本之间的同模态公共空间,借助跨模态匹配与同模态匹配相结合的思路,在两类公共空间中充分挖掘多种模态之间的语义信息,以提升模型检索性能。

1.3 研究内容及技术路线

森林疗养作为我国绿色可持续发展林业新模式,为广大人民群众带来健康福祉。本研究从林学会森林疗养分会亟需实现疗养师在线培训需求出发,围绕 T2VR 任务中仅在单个公共空间或多个跨模态公共空间中难以有效挖掘文本和视频丰富语义信息实际问题,提出一种基于视频字幕和多空间学习的检索模型 TVRVCML,旨在设计开发一个森林疗养课程培训系统,服务于培训森林疗养师,并提供高效准确的视频检索功能。本文主要研究内容如下:

(1) 基于视频字幕和多空间学习的检索模型设计与实现。本文围绕 T2VR 任务深入研究基于多个公共空间构建和处理的模型,发现这类方法侧重于仅构建多个跨模

态空间以进行跨模态匹配,缺少对视频本身自带字幕等描述文本信息的挖掘,难以有效利用文本和视频之间的潜在关联。同时缺少对多个公共空间关系建模,忽略了不同公共空间对于整体检索性能的重要性。针对这些问题,本文提出 TVRVCML 模型,其包括特征表示、多空间构建和多空间融合三层结构。为了构建多个公共空间,首先采用多种不同类型的编码器分别对查询文本、视频和视频字幕进行特征表示。借助跨模态匹配和同模态匹配相结合的思路做出改进,一方面构建查询文本与视频之间跨模态公共空间,另一方面构建查询文本与视频字幕之间同模态公共空间。此外,通过在多个公共空间中引入自注意力机制策略,为多空间分配权重,建模不同公共空间关系,以提升模型检索能力。

(2) 验证 TVRVCML 模型性能的实验设计与开展。为多方面评估 TVRVCML 模型表现,本文进行多层次实验。首先,在三个基准数据集 MSVD、MSR-VTT 和 TGIF 上与四个先进模型进行对比实验,以验证模型设计合理性。同时,在 MSVD 数据集上进行消融实验,通过观察替换 TVRVCML 模型中某个模块后的检索效果,以证明添加模块对整体检索准确性具有正向促进作用。此外,构建模型超参敏感性实验。

(3) 森林疗养课程培训系统的设计与实现。针对森林疗养在线培训需求,本文采用 Vue 和 Spring Boot 前后端分离开发模式研建一个 Web 端森林疗养课程培训系统。该系统分为学员端和管理员端,不仅能为学员提供友好、实用的系统培训服务,还能管理员提供资源管理、课程管理、资源管理和学员管理等功能模块。同时,通过将 TVRVCML 模型应用于本系统的课程视频检索业务,以缓解用户检索困难问题。

本文技术路线图如图 1.1 所示:




图 1.1 技术路线图

Figure 1.1 Diagram of technical route

1.4 论文组织结构

本研究分为五个章节进行，各章节具体内容安排如下：

第一章：绪论。本章首先阐述基于 T2VR 检索的森林疗养课程培训系统研究背景及意义。然后详细介绍在线课程培训系统、森林疗养课程培训系统和文本视频跨模态检索算法的国内外研究现状，分析其现状和可能存在的局限性。最后对本文主要研究内容和技术路线进行说明。

第二章：文本视频检索相关技术介绍。本章首先对深度学习时代下 T2VR 任务中最常用的基于公共空间学习方法进行阐释，然后对其涉及的核心技术，即文本特征表示、视频特征表示和公共空间学习展开详细介绍，并进行分类、分析和总结，同时对其优缺点进行评析。

第三章：基于视频字幕和多空间学习的文本视频检索。本章首先介绍了 TVRVCML 模型设计背景以引出创新动机。接着说明其整体结构，并按照模型层次关系详细介绍每层结构设计。为验证 TVRVCML 模型性能，本章从数据集描述和评价指标入手，同时说明实验运行环境和模型参数设置。最后，通过介绍基线模型并构建对比实验、消融实验和模型超参敏感性实验，对实验结果进行深入分析，旨在从数据和实验层面论证 TVRVCML 模型的有效性和优越性。

第四章：森林疗养课程培训系统研建。本章首先从林学会森林疗养分会亟需实现疗养师在线培训实际情况出发，对本系统进行需求分析说明，然后阐述其架构设计、功能模块设计和数据库设计。接着详细介绍了系统关键功能模块的详细设计和实现，以及系统的功能性测试和非功能性测试。

第五章：总结与展望。本章回顾总结了本文在 T2VR 检索算法研究上的主要工作及成果，并论述了研建一个森林疗养课程培训系统的意义，同时依据目前的研究方向对基于公共空间学习的 T2VR 算法和森林疗养课程培训系统的未来工作进行了展望。

2 文本视频检索相关技术介绍

文本视频检索相关技术涉及目前人工智能两大热门研究方向，即自然语言处理和计算机视觉。由于文本和视频属于不同模态，两者之间存在天然语义鸿沟，因此难以直接计算两者之间相似性。目前主流的解决方案是基于公共空间学习的方法。首先，使用编码器分别获取文本和视频特征表示，将其转换为可以建模和计算的向量形式。随后，将这两种模态特征表示映射到公共空间中，并通过距离函数计算两者相似度。因此，关键技术为文本、视频特征表示以及公共空间学习。下面将展开详细介绍。

2.1 文本特征表示技术

在文本特征表示方面，旨在将查询文本转化为计算机可以建模和计算的向量形式。对于文本视频检索任务而言，文本特征表示质量对于跨模态检索最终结果的准确性和可靠性具有重要影响。目前，主流的文本特征表示方法主要包括词袋模型、词向量模型和深度神经网络模型三种类型。

2.1.1 词袋模型

词袋模型（Bag-of-Words，简称 BoW）是一种简单而有效的文本特征表示方法。在词袋模型中，文本被表示为一个 N 维数值向量， N 表示词典中所有单词个数。词典中的每个单词对应一个维度，而向量中每个元素表示该单词在当前查询文本中出现的次数。如图 2.1 所示。




图 2.1 基于词袋模型的文本特征表示

Figure 2.1 Text feature representation based on Bag-of-Words model

词袋模型优点在于易于理解和实现，但由于它忽略单词之间顺序，导致难以挖掘词意或词序等信息。尽管如此，词袋模型依旧存在重要价值。一方面，词袋模型在实际应用中通常作为基线模型，用于比较。另一方面，词袋模型在文本视频检索任务中通常作为获取文本特征表示的模型之一，搭配其他模型共同使用。例如，Li 等人^[12]提出一种 W2VV++模型，通过组合使用三种文本编码器模型对查询文本分别提取全局、局部和时序的特征表示。Dong 等人^[24]提出一种多级编码策略，同样首先使用词袋模型对查询文本进行向量表示，作为一级文本特征表示策略。

2.1.2 词向量模型

词向量概念最早由 Hinton 等人^[25]提出。不同于词袋模型仅考虑词典单词在查询文本内出现次数，词向量模型会衡量当前中心单词和上下文信息。首先，通过将文本单词投影到向量空间中，将其转换为连续低维向量表示。应用最广泛的两种词向量模型为 Word2Vec 模型^[26]和全局向量表示（Global vectors for word representations，简称 Glove）模型^[27]。Word2Vec 模型基本思想是通过学习上下文单词来预测当前单词的向量表示。上下文单词窗口数量一般选择 3 个，即上下文单词选择待预测单词的前 3 个和后 3 个。Word2Vec 模型可以细分为连续词袋（Continuous Bag-of-Words，简称 CBoW）模型^[28]和跳字（Skip-gram）模型^[29]。CBoW 模型主要目标是通过学习中心单词的上下文词向量，来预测中心单词词向量。例如，对于句子“猫喜欢吃鱼”，CBoW 模型可能会将“鱼”作为中心单词，“猫”和“喜欢吃”作为上下文单词。而跳字模型与 CBoW 模型恰恰相反，其通过中心单词预测上下文词向量。如图 2.2 所示。




图 2.2 基于 Word2Vec 的文本特征表示

Figure 2.2 Text feature representation based on Word2Vec model

相较于 Word2Vec 模型通常利用中心单词临近的上下文单词为学习目标，即局部特征。Glove 模型则利用共现矩阵构建当前中心单词的全局上下文信息，使得训练出的词向量包含全局特征。在获得词向量后，通常是将文本中所有词向量进行池化操作来获得最终文本特征表示，如平均池化或最大池化。平均池化将每个单词对应词向量的平均值作为文本特征表示，最大池化将所有词向量在每个维度的最大值作为文本特征向量。

2.1.3 深度神经网络模型

上述两种文本特征表示方法简单且有效，但难以挖掘文本深层次语义信息。因此，为了提高文本特征表示能力，基于深度神经网络模型的文本特征表示方法被提出。其具体可以细分为三种类型，即基于 RNN（Recurrent Neural Network）的文本特征表示模型、基于 CNN（Convolutional Neural Network）文本特征表示模型和基于 Transformer 的文本特征表示模型。

（1）基于 RNN 的文本特征表示

RNN 作为一种序列模型，通过连接神经元来处理序列数据。在处理文本时，RNN 可以对文本中每个单词或字符进行建模，并利用前一时刻输出作为下一时刻输入，从而捕获文本上下文信息以生成文本特征表示。如图 2.3 所示。




图 2.3 基于 RNN 的文本特征表示

Figure 2.3 Text feature representation based on RNN model

在 T2VR 任务中，早期研究中使用经典 RNN 模型较多。首先利用 RNN 模型对文本进行特征表示，再对视频和文本统一建模。除了使用 RNN 之外，长短期记忆网络^[30]（Long Short-Term Memory，简称 LSTM）作为 RNN 一种改进模型，通过引入门控机制来处理长序列数据，有效存储和传递长期上下文信息。Otani 等人^[31]利用

LSTM 对特定文本进行特征表示，再进行视频和文本特征融合。Chen 等人^[32]使用双向 LSTM 对文本上下文信息进行建模，构建查询文本为正向和逆向词序列以获取上下文感知的词向量。与此同时，门控循环单元^[33]（Gated Recurrent Unit，简称 GRU）作为简化版的 LSTM，具有更少的参数和计算量。GRU 通过更新门和重置门来控制序列数据传递，同样可以捕捉到文本上下文信息。例如，Mithun 等人^[15]将词向量输入到 GRU 中以获取文本特征表示。

（2）基于 CNN 的文本特征表示

CNN 广泛应用于图像处理任务，同时也可以用于文本特征表示。类似于图像中像素，文本可以看作是一系列字符和单词。在将文本处理为词向量或字符向量之后，CNN 可以通过卷积操作捕获文本局部特征，如单词组合、语法结构等。随后，通过池化操作获取全局文本特征表示。如图 2.4 所示。




图 2.4 基于 CNN 的文本特征表示

Figure 2.4 Text feature representation based on CNN model

CNN 具有并行处理能力，能够快速捕获文本局部特征。在 T2VR 任务中，CNN 在文本特征表示中同样具有广泛应用。例如，Fan 等人^[34]利用一维 CNN 对文本进行编码，然后在多个不同尺度上提取文本局部特征。Miech 等人^[16]通过网络局部聚合描述符向量（Network Vector of Locally Aggregated Descriptors，简称 NetVLAD）将输入的词向量聚合为文本特征表示。同样是使用一维 CNN 模型，Dong 等人^[24]提出多级编码策略，实际上是使用一维 CNN 再次处理经过双向 GRU 编码后的文本特征。借助 CNN 和 RNN 结合的思路，提取文本中单词之间局部关系，随后通过池化操作获取查询文本特征表示，同样获得良好效果。

(3) 基于 Transformer 的文本特征表示

与 RNN 和 CNN 不同，Transformer 模型没有循环或卷积操作，它利用自注意力机制^[35]（Self-Attention Mechanism）来组建网络，允许模型处理序列数据的同时能够关注到输入序列中所有位置。自注意力机制核心思想是通过对比输入序列中不同位置元素进行比较和计算，从而捕捉到它们之间关系和重要程度。如图 2.5 所示。




图 2.5 自注意力机制计算过程

Figure 2.5 The calculation process of self-attention mechanism

自注意力机制工作原理是一个对输入序列中不同位置元素相互关注和计算过程，它不依赖于固定序列顺序，能够灵活关注到序列中任意位置。自注意力机制主要借助查询向量（query）、键向量（key）和值向量（value）来实现。以“男孩踢足球”这个输入文本序列为例。首先，将查询文本转换为词向量，用 x_1 来表示“男孩”，用 x_2 表示“踢”，用 x_3 表示“足球”，从而得到输入文本向量表示为 $\{x_1, x_2, x_3\}$ 。接下来，计算查询文本每个单词所对应的查询向量、键向量和值向量。以 x_1 为例，通过与三个矩阵 W_1 ， W_2 和 W_3 做矩阵相乘，分别得到 x_1 对应的查询向量 q_1 、键向量 k_1 和值向量 v_1 。其中，上述三个矩阵为参数矩阵，需要在模型训练中学习。随后，通过将 x_1 的查询向量 q_1 与所有词的键向量 k_i 计算内积，得到其余单词对于当前单词的重要程度和关联性。最后，借助SoftMax激活函数对计算结果进行归一化，并将其与全部值向量做加权求和以得

到 x_1 对应的输出向量 r_1 。如公式（2-1）所示。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-1)$$

其中， Q 、 K 和 V 分别表示查询向量、键向量和值向量，通过文本词向量与参数矩阵相乘所得。 d_k 表示键向量维度，该参数目的在于控制计算结果，防止结果过大导致后续可能出现梯度消失问题。

在通过自注意力机制捕获单词之间依赖关系之后，Transformer 模型内部通常使用前馈神经网络（Feed-forward Neural Network）对序列中每个位置向量表示做进一步转换。最后，Transformer 会通过层规范化（Layer Normalization）来稳定模型训练，并生成最终文本特征表示。此外，随着 BERT^[36]在自然语言处理任务中取得良好成果，文本视频检索领域也开始将其作为一种文本特征表示方法。BERT 是来自 Transformer 的双向编码器（Bidirectional Encoder Representations from Transformer）简称。BERT 与 Transformer 主要区别在于，前者能够处理多个输入序列，而后者只能处理单个输入序列。因此，在使用 BERT 模型进行文本特征表示时，会通过添加标记[SEP]来分割不同句子，作为两个句子或序列之间边界。另外，文本中所有单词标记的最前面会添加标记[CLS]，对应特征通常代表文本全局语义信息。如图 2.6 所示。




图 2.6 基于 BERT 的文本特征表示

Figure 2.6 Text feature representation based on BERT model

随着 Transformer 和 BERT 在自然语言处理任务上表现出良好效果，其在 T2VR 任务中文本特征表示方面得到广泛应用。例如，Li 等人^[37]提出一种基于 Transformer 的联合视觉语言编码器，以此学习视频和文本的联合特征。另外，Li 等人^[19]提出一种文本编码器组合框架 SEA，将 BERT 作为其中一种文本特征表示策略。

2.2 视频特征表示技术

视频特征表示是指通过一系列技术和方法，将视频模态数据转换为可用于建模和计算的向量形式。由于视频实际上是由连续图像帧组成，因此一种常用技术是将帧级特征聚合为视频级特征。此外，由于视频中包含多种模态信息，如画面、动作、声音、字幕等。另一种常用技术是采用多种专家编码器提取视频中特定模态特征并进行特征融合，以此得到视频特征表示。下面将对两种相关技术展开详细介绍。

2.2.1 帧级特征聚合为视频级特征

该方法对视频特征表示处理过程可分为三个步骤：选取关键帧、提取帧级特征、聚合为视频级特征。如图 2.7 所示。




图 2.7 帧级特征聚合为视频级特征

Figure 2.7 Aggregating frame level features into video level features

为了有效表示视频特征，第一步是选取视频关键帧。常见方式有三种：随机采样、均匀采样和稀疏采样。随机采样是指每秒随机选择几帧，这种方法简单但有可能错过重要帧。均匀采样则是按照固定时间间隔分割视频，确保视频完整性。稀疏采样则是根据特定准则或算法选择关键帧。例如，Lei 等人^[38]采用稀疏采样方法，利用端到端学习的 CLIPBERT 模型提取帧级特征。

选定关键帧后，第二步是提取关键帧的帧级特征。由于视频中每帧都类似于静态图像，因此可以采用处理图像的方式来处理帧级特征。Torabi 等人^[39]选择平均采样关键帧方式，并使用预训练的 VGG-19 模型^[40]从倒数第二层提取帧级特征。Mithun 等人^[16]同样选择平均采样关键帧方式，并将其输入到预训练的 ResNet-152 模型中提取帧级特征。除了利用 CNN 模型可以提取视频帧级特征之外，Dosovitskiy 等人^[41]提出

一种通用工具视觉 Transformer，专门用于提取图像或者视频帧级特征。

在提取视频帧级特征之后，为了得到视频整体特征表示，第三步是利用平均池化、最大池化、RNN 模型等技术将帧级特征聚合成为视频级特征。Dong 等人^[21]提出一种效仿人类阅读的策略，将帧级特征输入到双向 GRU 模型中，分别从前向和后向提取时间信息并执行平均池化，以生成沿着时间维度的整个视频级表示。Yang 等人^[42]提出一种树增强跨模态编码方法，通过 ResNet-152 模型和 GRU 模型分别提取帧级特征，并通过注意力机制模块将二者聚合成视频级特征。

2.2.2 多种专家特征融合

由于视频本身包含多种不同模态信息，如画面、动作、声音、字幕文本等。因此，另一种主流的视频特征表示方法是使用多个“专家”编码器提取视频中多个模态特征，每个专家只致力于从指定模态中提取特征。如图 2.8 所示。




图 2.8 多种专家特征融合

Figure 2.8 Fusion of multiple expert features

在提取视频中各种模态特征之后，首要问题聚合由多个专家特征组成的视频表示。Yu 等人^[43]通过降低视频中音频模态特征维度，与视频画面特征直接连接以获得最终视频特征表示。而 Miech 等人^[16]和 Liu 等人^[44]则通过门控机制调节各专家特征之间关系，并进一步通过平均池化或 VLAD 机制做特征融合。在 Liu 等人提出的协作专家 (Collaborative Expert, 简称 CE) 模型基础上, Gabeur 等人^[13]提出多模态 Transformer (Multi-modal Transformer, 简称 MMT) 模型以融合多模态特征，并对视频时间信息进行建模以生成视频特征表示。另外，Wang 等人^[45]提出了一种端到端的 T2VLAD 框架，利用多个专家编码器来提取相应视频局部特征，并将来自不同专家的所有视频特征输入到一个自注意力机制层，以增强基于跨模态局部语义关系的特征。

2.3 公共空间学习技术

目前 T2VR 任务主流方法是基于公共空间学习的方法。在上述两个章节基础上，得到了文本特征向量和视频特征向量。为了进行特征匹配和模态相似度计算，需要将两种向量映射到公共空间中。在该空间中，主要涉及距离度量函数选取、相似度计算和损失函数优化这三个方面相关技术。下面将分别展开介绍。

(1) 距离度量函数

为计算查询文本和视频之间模态相似度，需要采用距离度量函数对向量进行计算。在 T2VR 任务之中，欧式距离（Euclidean Distance）和余弦距离（Cosine Distance）是度量两个向量之间相似性或差异性最常用方法。

① 欧式距离

欧式距离，即欧几里得距离。主要用于反应两个向量之间的直线距离，是最常见的距离度量函数之一。以向量 $X(x_1, x_2, \dots, x_n)$ 和向量 $Y(y_1, y_2, \dots, y_n)$ 为例，两者之间的欧式距离 d_{XY} 如公式（2-2）所示。

$$d_{XY} = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (2-2)$$

其中，欧式距离越小代表两个向量越接近，且取值范围是非负数。

② 余弦距离

余弦距离，通常来说代表余弦相似度。主要通过两个向量之间的余弦夹角来衡量相似性或差异性，其取值范围为 $[-1, 1]$ 。当余弦距离越靠近-1时，余弦夹角越小，代表两个向量之间相似度越高。反之，当余弦距离越靠近1时，余弦夹角越大，代表两个向量之间相似度越低。同样以向量 $X(x_1, x_2, \dots, x_n)$ 和向量 $Y(y_1, y_2, \dots, y_n)$ 为例，两者之间的余弦距离 $\text{sim}(X, Y)$ 如公式（2-3）所示。

$$\text{sim}(X, Y) = \cos(\theta) = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}} \quad (2-3)$$

其中， θ 代表两个向量间余弦夹角。一般来说，欧式距离对向量大小更加敏感，可以反映出两个向量之间绝对距离。余弦距离对向量方向更加敏感，更加适用于高维向量的相似性度量。

(2) 相似度计算

以余弦距离函数为例，对文本视频相似度计算展开说明。假设经过文本编码器后获取文本特征表示为 $x_t \in R^{d_1}$ ，经过视频编码器后获取视频特征表示为 $x_v \in R^{d_2}$ 。其中， d_1 和 d_2 分别代表文本特征和视频特征向量维度。则可以计算文本特征表示和视频特征表示在向量维度为 d 的公共空间中映射关系。如公式（2-4）和（2-5）所示。

$$t = W_1 x_t \quad (2-4)$$

$$v = W_2 x_v \quad (2-5)$$

其中，参数矩阵 $W_1 \in R^{d_1 \times d}$ ， $W_2 \in R^{d_2 \times d}$ 。经过上述映射后，文本和视频在公共空间中的表示分别为 t 和 v 。然后，使用余弦距离度量函数计算文本与视频之间距离。如公式 (2-6) 所示。

$$\text{sim}(t, v) = \frac{t \cdot v}{\|t\| \cdot \|v\|} \quad (2-6)$$

其中， $\|t\|$ 和 $\|v\|$ 分别代表文本向量和视频向量模长。

(3) 损失函数优化

损失函数优化核心目标是使语义相近的文本视频正样本对在公共空间中距离更近，而不相近的文本和视频负样本对距离更远。例如，Yang 等人^[42]在大批量数据中选择困难负样本，并根据相似度排名选择前 5 个负样本对计算平均损失，以证明困难样本对于整体检索效果的影响。Mithun 等人^[16]通过引入权重函数的方式，确保文本视频正样本对之间距离更相近，最终排名更靠前。另外，MMT 模型采用最大边际排序损失^[13]来限制文本视频间相似度距离，直接通过比较正样本和负样本来引导模型缩小正样本间距离，扩大负样本间距离。

2.4 本章小节

本章首先简要概述了 T2VR 任务在深度学习时代下最常用的基于公共空间学习方法的思路步骤，其次详细介绍了文本特征表示相关技术，包括词袋模型、词向量模型和深度神经网络模型。接着详细说明了视频特征表示相关技术，包括帧级特征聚合为视频级特征和多种专家特征融合两种方法。最后，说明了公共空间学习相关技术。

3 基于视频字幕和多空间学习的文本视频检索

本章首先介绍 TVRVCML 模型设计背景以引出创新动机。接着说明其整体结构，并按照模型层次关系详细介绍每层结构设计。为验证 TVRVCML 模型性能，本章从数据集描述和评价指标入手，同时说明实验运行环境和模型参数设置。最后，通过介绍基线模型并构建对比实验、消融实验和超参敏感性实验，对实验结果进行深入分析，旨在从数据和实验层面论证 TVRVCML 模型的有效性和优越性。

3.1 引言

随着在线视频平台快速发展，视频数据大量产生，用户获取目标视频成本变大。在 T2VR 任务中，基于公共空间学习的方法是当前深度学习时代下最常用方法。按照算法流程，其核心思路分为三个步骤：特征表示、特征匹配和相似度计算，并根据相似度大小将前 k 个与文本查询语义相关视频返回给用户，以达到跨模态检索目的。

为捕获文本和视频之间模态相似度，当前大部分 T2VR 研究集中于构建一个公共空间，以实现模态匹配和相似度计算。例如，Li 等人^[12]提出一种 W2VV++ 模型，将多个文本特征向量连接为一个长特征向量来组合多种文本编码器，然后利用全连接层把文本特征向量和视频特征向量映射到一个公共空间中。另外，Dong 等人^[24]提出一种双编码（Dual Encoding，简称 DE）模型，分别使用初级编码器以及 bi-GRU 模型组合的方式对文本和视频进行多级编码，随后进行向量连接，并将最终的文本和视频特征表示映射到构建的单个公共空间中。然而，文本和视频间跨模态检索的本质实际上是两种模态数据之间的语义关系，而这两者都具有丰富语义信息。比如，视频包含画面、字幕、动作和音频等，以及查询文本中包含动词、名词、形容词和语气词等。因此，仅在单个公共空间中同时匹配多种不同的文本和视频语义信息存在较大困难。目前，更多研究开始关注构建多个跨模态公共空间，以缓解单个公共空间中难以捕获多语义关系问题。例如，Dong 等人^[20]在 DE 模型语义公共空间的基础上，增加概念公共空间，以双空间学习的方式进行特征匹配和模态相似度计算。Li 等人^[19]提出了多种文本编码器组合 SEA 框架，构建出 k 个跨模态公共空间， k 取决于文本编码器数量。然而，针对视频这种本身就具有多种模态信息的数据而言，仅使用多个跨模态公共空间同样面临挑战。视频中不仅包含与查询文本不同模态的图像或音频等信息，同样包含与查询文本相同模态的视频字幕等描述文本信息。忽视同模态数据之间交互可能导致模态孤立，尽管使用多个跨模态公共空间，语义鸿沟仍有可能存在。这将会导致准确匹配和理解文本与视频之间丰富的语义关系变得困难。

与此同时，不同公共空间对于文本和视频具有不同重要性，忽视它们之间的关系可能导致信息丢失，影响对文本和视频语义关系全面理解。如果没有权重分配，可能会导致不均衡的匹配结果，某些重要语义信息得不到充分考虑。

针对上述问题，本文提出一种基于视频字幕和多空间学习的文本视频检索模型 TVRVCML，通过构建跨模态公共空间和同模态公共空间，并在多个公共空间中引入自注意力机制来优化检索性能。首先，该模型通过多种类型文本编码器提取多个文本特征向量，并与视频向量交互构建出多个跨模态公共空间。与此同时，增加视频字幕文本编码器，借助查询文本向量与视频字幕向量之间交互构建出一个同模态公共空间。在两类公共空间中分别处理跨模态信息和同模态信息，发挥跨模态匹配与同模态匹配相结合优势。从而更加全面地建模和计算多种模态特征向量间关系，以提高模型检索性能。此外，在多个公共空间中引入自注意力机制，处理多空间之间权重分配，从而建模不同公共空间关系并处理每个公共空间对于模型整体检索性能的差异性贡献。

综上所述，本章主要工作如下：

(1) 提出一种基于多空间学习处理文本视频跨模态检索的模型 TVRVCML。在构建多个跨模态公共空间基础上，构建视频字幕特征向量与查询文本特征向量之间的同模态公共空间。借助跨模态匹配与同模态匹配相结合的思路，分别处理查询文本与视频之间跨模态信息与同模态信息，以提高模型综合检索性能。

(2) 引入一种有效的权重分配策略来处理多个公共空间关系。通过在多个公共空间中引入自注意力机制，对不同公共空间进行权重分配，以建模不同公共空间关系和对模型整体检索性能的差异性贡献。

(3) 选取 T2VR 任务中公认的 MSVD、MSR-VTT 和 TGIF 基准数据集，在三个数据集上通过与四个先进模型进行对比实验，并选用三个评价指标评估模型表现，以验证 TVRVCML 模型设计合理性。同时，在 MSVD 数据集上构建消融实验，进一步说明模型创新模块有效性。最后，构建超参敏感性实验，验证模型参数正确性。

3.2 模型结构设计

3.2.1 模型整体结构

为构建多个公共空间，TVRVCML 模型首先采用多种不同类型编码器分别对查询文本、视频和视频字幕进行特征表示，以保证特征向量间具有差异性，同时将多模态数据处理为可以建模和计算的向量化形式。在构建多个公共空间过程中，借助跨模态匹配与同模态匹配相结合思路，不仅构建查询文本特征向量与视频特征向量之间多个跨模态公共空间，而且构建查询文本特征向量与视频字幕特征向量之间的同模态公共空间，从而更加全面地学习和匹配查询文本与视频之间丰富的语义关系，充分挖掘多模态数据信息，以提高检索模型性能。此外，通过在两类多空间中引入自注意力机制，融合多个公共空间匹配结果，从而建模和计算不同公共空间关系和对整体检索性能的差异性贡献。TVRVCML 模型结构整体上分为三个部分：特征编码层、多空间构建层以及多空间融合层。

TVRVCML 模型整体结构设计如图 3.1 所示。




图 3.1 TVRVCML 模型结构

Figure 3.1 Structure of Video Captions and Multi-space Learning retrieval modal

(1) 特征编码层

为构建多个公共空间,首先按照 T2VR 任务中常用的编码方式对多模态数据进行特征表示。其中,查询文本选用多种不同类型文本编码器进行文本特征表示,以确保特征向量间具有差异性。视频使用预训练的 ResNeXt-101 模型和 ResNet-152 模型^[12]提取帧级特征表示,并通过平均池化和向量连接聚合成视频级特征。此外,使用双向 GRU 模型作为视频字幕编码器进行文本特征表示,以构建同模态公共空间。

(2) 多空间构建层

为了更全面地学习和匹配查询文本与视频之间语义关系,本文构建出多个跨模态公共空间和一个同模态公共空间。在通过全连接层进行向量维度对齐之后,首先借助多个文本特征向量与视频特征向量之间交互构建出多个跨模态公共空间。在此基础上,通过文本特征向量与视频字幕特征向量之间交互构建出一个同模态公共空间。

(3) 多空间融合层

通过在两类多空间中引入自注意力机制,融合多个公共空间匹配结果,从而建模和计算不同公共空间关系和对整体检索性能的差异性贡献。另外,借助组合损失函数优化模型训练效果,使文本视频正样本向量对距离更近。

3.2.2 特征编码层

(1) 查询文本特征表示

本文采用由序列模型和非序列模型组成的文本编码器组合对查询文本进行编码。借助多种不同类型的文本编码器，不仅可以充分挖掘查询文本中复杂的词序、词意等语义信息，还能保证多种文本特征向量之间具有差异性。具体而言，包括目前主流的四种文本编码器，即词袋、W2V (Word2Vec)、GRU 和 BERT 模型。

① 词袋模型

词袋模型作为经典且有效的文本特征表示方法，查询文本被看作是一个无序词袋，其文本特征向量维度取决于预先定义的词汇表大小。其中，向量中每个元素表示对应于词汇表单词在查询文本中的出现次数。设 $f(t_{bow})$ 是通过词袋模型得到的查询文本特征表示。如公式 (3-1) 所示。

$$f(t_{bow}) = (c(w_1, t), c(w_2, t), \dots, c(w_m, t)) \quad (3-1)$$

其中， $c(w_i, t)$ 表示词汇表中单词 w_i 在查询文本 t 中出现次数， m 是词汇表中单词个数，同时代表 $f(t_{bow})$ 的向量维度大小。另外，由于 T2VR 任务中查询文本一般较短，因此使用词袋模型得到的文本特征表示向量 $f(t_{bow})$ 较稀疏。

② W2V 模型

与词袋模型得到的稀疏向量不同，W2V 模型通常在大型文本语料库中利用神经网络首先生成单词级密集向量，然后对每个单词的词向量做平均以表示整个查询文本。因此，查询文本特征向量的维度与词向量维度相同。设 $f(t_{w2v})$ 是由 W2V 模型得到的查询文本特征表示。如公式 (3-2) 所示。

$$f(t_{w2v}) = \frac{1}{n} \sum_{i=1}^n w2v(w_i, t) \quad (3-2)$$

其中， $w2v(w_i, t)$ 表示查询文本中当前单词 w_i 对应的 W2V 特征向量， n 代表查询文本中单词个数，使用 W2V 模型得到的文本特征表示向量 $f(t_{w2v})$ 较密集。

③ GRU 模型

上述两种文本编码方便且有效，但由于忽略了查询文本中单词顺序导致无法分辨出 “the boy hit the ball” 和 “the ball hit the boy” 这两个句子。因此，本文使用 RNN 类型网络 GRU 模型来补充查询文本中单词之间顺序关系建模，其通过迭代产生递归隐藏状态序列 $\{\vec{h}_1, \vec{h}_2, \dots, \vec{h}_n\}$ ，实现顺序关系建模。根据文献方法得到时间步 s 处的隐藏状态向量 $\vec{h}_s$ ，由当前单词 w_s 和前一个时间步隐藏状态 $\vec{h}_{s-1}$ 共同确定。此外，通过对隐藏状态向量序列取平均，即可获得通过使用 GRU 模型的查询文本特征表示 $f(t_{gru})$ 。如公式 (3-3) 所示。

$$f(t_{gru}) = \frac{1}{n} \sum_{s=1}^n gru(\vec{h}_s) \quad (3-3)$$

其中, n 同样表示查询本文中单词个数。

④ BERT 模型

BERT 模型借助堆叠 L 个双向 Transformer 块构建, 利用多个 Transformer 块渐进传递编码为查询文本生成词向量。每个 Transformer 模块由一个自注意力网络和一个前馈网络组成。首先, 自注意力网络接收前一个 Transformer 块编码, 通过自注意力机制来权衡彼此重要性, 并相应地生成新编码。随后, 这些编码并行地送到前馈网络中以生成该 Transformer 块的输出编码。最终, 同样采用取平均获得借助 BERT 模型得到的查询文本编码 $f(t_{bert})$ 。如公式 (3-4) 所示。

$$f(t_{bert}) = \frac{1}{n} \sum_{i=1}^n bert(w_i, L-1) \quad (3-4)$$

其中, $bert(w_i, L-1)$ 表示由倒数第二个 Transformer 块生成的当前第 i 个词向量。在本文中, 采用包含 $L=12$ 块 Transformer 组成的 BERT 模型。

(2) 视频特征表示

在视频方面, 本文采用平均采样视频帧方式, 利用预训练的 CNN 类型网络提取帧级特征, 再通过平均池化将帧级特征连接和聚合成视频级特征。具体来说, 首先以 0.5 秒预定间隔均匀采样 n 帧视频序列, 并对每帧使用预训练的 ResNeXt-101 模型和 ResNet-152 模型分别提取帧级特征向量。对于一个给定视频 V , 其通过帧级特征向量序列 $\{v_1, v_2, \dots, v_n\}$ 组合表示。其中, v_n 代表第 n 帧的帧级特征向量。通过平均池化将帧级特征聚合成视频级特征后, 并将两个 CNN 类模型所得视频级特征向量进行连接, 得到视频特征表示 $f(V)$ 。如公式 (3-5) 所示。

$$f(V) = \frac{1}{n} \sum_{i=1}^n v_i \oplus \frac{1}{n} \sum_{j=1}^n v_j \quad (3-5)$$

其中, $\oplus$ 符号代表向量连接, v_i 和 v_j 分别代表使用预训练的 ResNeXt-101 模型和 ResNet-152 模型所获得的帧级特征。

(3) 视频字幕特征表示

在视频字幕方面, 为构建查询文本与视频字幕之间的同模态公共空间, 增加字幕文本编码器对视频字幕 c 进行特征编码。由于视频附带明显地时序信息, 因此, 本文选用双向 GRU 模型作为视频字幕编码器。通过前向 GRU 和以相反顺序编码序列的后向 GRU 来捕获视频字幕中文本上下文信息。设 $\{\vec{h}_1, \vec{h}_2, \dots, \vec{h}_n\}$ 和 $\{\overleftarrow{h}_1, \overleftarrow{h}_2, \dots, \overleftarrow{h}_n\}$ 分别作为前向 GRU 和后向 GRU 的隐藏状态向量序列, 通过双向 GRU 模型获得视频字幕特征表示 $f(c)$ 。如公式 (3-6) 所示。

$$f(c) = \frac{1}{n} \sum_{s=1}^n bigru(\vec{h}_s \oplus \overleftarrow{h}_s) \quad (3-6)$$

其中, $\oplus$ 符号代表向量连接, s 是当前时间步, n 代表视频字幕中单词个数。综上, 本文使用多种不同类型编码器对查询文本、视频和视频字幕转换为可以建模和计算的向量化特征表示, 接下来将在多个公共空间中分别进行特征匹配和相似度计算。

3.2.3 多空间构建层

为了更全面地学习和匹配查询文本与视频之间语义关系,并利用丰富多模态信息,本文在构建多个公共空间时做出改进。在构建跨模态公共空间的基础上,构建出视频字幕与查询文本之间的同模态公共空间。借助跨模态匹配与同模态匹配相结合方法,以实现更好地检索效果。在多空间构建层中,主要进行特征对齐、特征匹配和相似度计算三个步骤。接下来将从跨模态公共空间和同模态公共空间两方面展开详细介绍。

(1) 跨模态公共空间

由于不同种类编码器对同一文本数据输出的特征向量维度不同,如表 3.1 所示。因此,在进行特征匹配之前,首先使用全连接层(Fully Connected,简称 FC)对多种文本向量维度进行放射变换,将特征向量统一对齐成 2048 维度。

表 3.1 文本编码器输出向量维度

Table 3.1 The vector dimension output by the text encoder

文本编码器	编码器类型	输出向量维度
BoW	序列模型	m
W2V	序列模型	500
GRU	非序列模型	1024
Bi-GRU	非序列模型	2048
BERT	非序列模型	768

m 代表词袋模型预定义词汇表中单词个数,其决定通过词袋模型获得的查询文本特征表示向量维度。将多种编码器获得的特征表示向量作为输入,借助全连接层进行放射变换,输出 2048 维度向量。以词袋模型的文本特征表示向量 $f(t_{bow})$ 为例,说明向量维度转换过程。如公式(3-7)所示。

$$f_c(t_1) = \sigma(W \cdot f(t_{bow}) + b) \quad (3-7)$$

其中,符号 σ 代表增加网络非线性能力的激活函数, W 和 b 分别是全连接层第一个隐藏层的放射变换矩阵和偏置项。经过特征向量对齐之后,得到同为 2048 维度查询文本特征表示向量,并分别使用 $f_c(t_1)$ 、 $f_c(t_2)$ 和 $f_c(t_3)$ 代表借助 BoW、W2V 和 GRU 模型在经过全连接层对齐后的查询文本特征向量表示。此外,视频特征表示向量同样使用公式(3-7)所示方法转换 2048 维度向量 $f_c(V)$ 。

由此,本文构建出 3 个跨模态公共空间,以进行特征匹配和模态相似度计算,并选用 T2VR 任务中最常使用的余弦相似度作为向量距离度量函数。则可计算在跨模态公共空间中查询文本与视频之间的跨模态相似度。如公式(3-8)所示。

$$cms_i = \text{cosine}(f_c(t_i), f_c(V)) \quad (3-8)$$

其中, cosine 为余弦相似度计算函数, cms_i 是模态相似度, 计数方式 $i=1, 2, 3$ 。

(2) 同模态公共空间

为了更全面地学习和匹配查询文本与视频之间丰富的语义关系, 充分挖掘多模态数据信息, 以提高模型性能。在构建 3 个跨模态公共空间的基础上, 构建出 1 个视频字幕特征向量与查询文本特征向量之间的同模态公共空间。具体来说, 首先将借助 BERT 模型获得的查询文本特征向量 $f(t_{\text{bert}})$ 和双向 GRU 模型所得视频字幕特征向量 $f(c)$ 进行向量维度对齐, 利用如公式 (3-7) 中使用全连接层进行放射变换方法, 分别将 $f(t_{\text{bert}})$ 和 $f(c)$ 转换成同为 2048 维度的特征向量, 并使用 $f_c(t_4)$ 和 $f_c(c)$ 表示。

在特征向量维度对齐之后, 本文构建出 1 个同模态公共空间, 以进行特征匹配和模态相似度计算, 发挥跨模态匹配和同模态匹配相结合优势, 并同样选取余弦相似度作为距离度量函数, 则可计算在同模态公共空间中查询文本与视频字幕之间的同模态相似度。如公式 (3-9) 所示。

$$\text{cms}_4 = \text{cosine}(f_c(t_4), f_c(c)) \quad (3-9)$$

其中, cosine 同样为余弦相似度计算函数, cms_4 代表同模态相似度。综上, 本文构建出 3 个跨模态公共空间和 1 个同模态公共空间, 在进行特征向量维度对齐之后, 分别将多个查询文本向量与视频向量以及查询文本向量与视频字幕向量映射到公共空间中进行特征匹配, 并选用余弦相似度作为距离度量函数得到模态相似度 cms_i 。其中, $i=1, 2, 3, 4$ 。然而, 不同公共空间对于文本和视频具有不同重要性, 忽视它们之间的关系可能导致信息丢失, 影响对文本和视频语义关系全面理解。如果没有权重分配, 可能会造成不均衡的匹配结果, 某些重要语义信息得不到充分考虑。因此, 需要引入一种有效的权重分配策略来处理多个公共空间关系。接下来将展开详细介绍。

3.2.4 多空间融合层

为了建模和计算两种类型多个公共空间之间关系, 衡量每一个公共空间对于模型整体检索性能的差异性贡献。本文引入一种有效的自注意力机制策略, 对每一个公共空间的特征匹配结果进行权重分配, 以提升模型检索性能。具体来说, 将检索模型的初始模态相似度以向量 $X_{\text{cms}} = \{\text{cms}_1, \text{cms}_2, \text{cms}_3, \text{cms}_4\}$ 来表示, 包括每个公共空间中特征匹配结果。并分别通过线性变换构建出查询向量 Q 、键向量 K 和值向量 V , 以进行权重计算。如公式 (3-10) 所示。

$$\begin{aligned} Q &= X_{\text{cms}} W^Q \\ K &= X_{\text{cms}} W^K \\ V &= X_{\text{cms}} W^V \end{aligned} \quad (3-10)$$

其中, W^Q 、 W^K 和 W^V 代表模型训练可学习的参数矩阵。随后, 通过引入自注意力机制, 计算每个公共空间中多模态特征向量之间自注意力权重 $\text{Attention}(Q, K, V)$ 。如公式 (3-11) 所示。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3-11)$$

其中, 首先计算查询向量与所有键向量转置点积, 除以 $\sqrt{d_k}$ 是防止点积结果过大。接着使用softmax函数对自注意力相关性进行数值转换以得到自注意力权重。最后将自注意力权重与初始模态相似度 X_{cms} 进行加权求和, 建模不同公共空间关系, 以得到整体模态相似度 cms 。如公式(3-12)所示。

$$cms = \text{Attention}(Q, K, V) \cdot X_{cms} \quad (3-12)$$

此外, 在多空间融合层中, 为优化模型检索性能, 本文采用组合损失函数方法。旨在使多模态正样本间距离更接近, 而负样本间距离更远离。为此, 本文选用改进的三重排序损失^[46](Improved Triplet Ranking Loss, 简称 ITRL)函数。不同于经典的三重排序损失函数随机选择负样本 $\mathcal{L}^-$ 来训练, ITRL 则在部分批量数据内选择最违反排序约束的负样本 $\mathcal{L}^{*-}$ 展开模型训练。如公式(3-13)所示。

$$\begin{cases} \mathcal{L}^{*-} = \arg\max_{\mathcal{L}^- \in batch} (\mathcal{L}^- - \mathcal{L}^+) \\ \mathcal{L}^{sig} = \max(0, \alpha + \mathcal{L}^{*-} - \mathcal{L}^+) \end{cases} \quad (3-13)$$

其中, argmax函数用来处理最值, batch代表一定数量的部分数据, 本文预定batch=128。 α 代表裕度参数, 根据VSE++模型^[46]设置 $\alpha=0.2$ 。 $\mathcal{L}^{sig}$ 为单个空间损失函数。由于TVRVCML模型采用两种类型多个公共空间进行特征匹配和相似度计算, 因此, 通过将每个公共空间中的单损失函数 $\mathcal{L}^{sig}$ 通过取平均的方式, 得到最终损失函数 $\mathcal{L}^{res}$ 。如公式(3-14)所示。

$$\mathcal{L}^{res} = \frac{1}{4} \sum_{i=1}^4 \mathcal{L}_i^{sig} \quad (3-14)$$

3.3 实验条件与环境设置

3.3.1 数据集描述

遵循现有研究工作^[50-53], 本文在T2VR任务中最常使用的3个基准数据集上进行实验: MSR-VTT、MSVD和TGIF。其中, 数据集的详细统计信息, 包括名称、年份、视频、视频描述文本和数据类型。如表3.2所示。

表 3.2 数据集详细统计信息

Table 3.2 The detailed statistical information on the dataset

数据集	年份	视频	视频文本	数据类型
MSVD	2011	1970	85,550	视频/文本
MSR-VTT	2016	7,180	200,000	视频/文本
TGIF	2016	102,068	125,781	GIF/文本

(1) MSVD 数据集^[47]

该数据集包含 1,970 个来自 YouTube 视频网站的视频剪辑片段,且每段视频对应约 40 条字幕等文本描述信息。遵循现有研究工作^[50-53],本文使用数据集中带有的文本描述作为查询文本,采用视频及其对应的字幕等描述文本进行实验。该数据集在 2011 年由微软公司创建,作为 T2VR 任务中最早的基准数据集之一。

(2) MSR-VTT 数据集^[48]

该数据集包含约 10,000 个同样来自 YouTube 视频网站的视频剪辑片段,每段视频长度为 10 到 30 秒之间,共有约 200,000 条描述视频内容的字幕等文本信息。本文同样使用视频及其描述文本组成的文本视频对进行模型训练。

(3) TGIF 数据集^[49]

该数据集包含约 100,000 段来自 Tumblr 社交平台的 GIF 格式视频,每个视频有 1 到 3 条文本描述,共有约 120,000 条关于视频的文本描述,使用文本视频对来训练。

另外,本文均采用标准数据集划分策略^[50]处理以上三个数据集。即 70%数据集的视频及其对应文本组成的文本视频对用于模型训练,20%数据集用于模型验证以调整模型参数,剩余 10%数据集用于模型训练结束后的性能测试。

3.3.2 评价指标

为客观评估检索性能,并与其他现有方法进行公平比较,遵循现有研究工作^[51-53],采用 T2VR 领域公认的三个评价指标:前 K 项召回率 (Recall@K, 记为 R@K)、中位数排序 (Median Rank, 记为 MdR) 和平均精度 (mean Average Precision, 记为 mAP)。

(1) R@K

R@K 表示在根据相似度排序返回的检索结果中,选取结果列表中前 K 项,其中包含正确检索结果的百分比。通常, K 取值为 1, 5 或 10 中一个数值。R@K 值越高,表明检索性能越好。如公式 (3-15) 所示。

$$R@K = \frac{r_{crt}}{r_{top-K}} \times 100\% \quad (3-15)$$

其中, r_{crt} 表示正确匹配结果数, r_{top-K} 是返回列表的前 K 项结果。

(2) MdR

MdR 表示在检索返回列表中第一个正确结果所在位置的中位数。MdR 值越低,代表第一个正确匹配结果在所有返回列表位置越靠前,即模型检索性能和准确率越高。

(3) mAP

mAP 表示所有查询在检索排名列表中正确匹配结果与所在位置相除的平均值。结合 R@K 和 MdR 指标一起使用,可以更全面地评估检索性能。R@K 关注正确匹配样本在前 K 个检索结果中比例, MdR 更侧重于第一个正确样本位置, mAP 衡量多个查询的平均检索精度,上述指标共同提供关于检索结果召回率和准确率信息。

3.3.3 实验运行环境

为确保实验可靠性与稳定性,实验运行环境包括软件环境和硬件环境。软件环境以 Ubuntu 操作系统作为实验基础,开发语言选用 Python,并以 PyTorch 作为深度学习框架。硬件环境主要包括 CPU 型号为英特尔 Xeon 系列, GPU 型号为英伟达 RTX 4090 系列。详细的软硬件环境配置参数如表 3.3 所示。

表 3.3 软硬件环境配置参数

Table 3.3 Software and hardware environment configuration parameters	
环境类型	配置参数
软件环境	操作系统: Ubuntu 18.04
	开发工具: VSCode
	开发语言: Python 3.8
	GPU 加速工具: CUDA 11.1
	深度学习框架: PyTorch 1.9.0
硬件环境	CPU 型号: Intel® Xeon® Platinum 8352V @ 2.10GHz
	GPU 型号: RTX 4090(24G)
	内存: 120GB
	硬盘: 80GB

3.3.4 模型参数设置

深度神经网络模型参数需要通过大量实验不断调整优化后确定,本文在模型训练过程中持续观察训练集与测试集上 R@K、MdR 和 mAP 值变化,最终设定一组包含公共空间维度、损失函数、激活函数以及训练轮次等参数。如表 3.4 所示,详细描述本文模型实验参数配置。

表 3.4 模型共享实验参数设置

Table 3.4 The experimental parameter configuration for the models sharing	
参数	配置
公共空间维度	2048
Transformer 块	BERT=12
损失函数	ITRL
裕度参数	$\alpha=0.2$
激活函数	ReLU 函数
学习率	0.0005
Epoch	10 (包括训练提前终止策略)
Batch_size	128

3.4 实验构建与结果分析

3.4.1 基线模型选取

为了客观评估基于视频字幕和多空间学习的 TVRVCML 模型效果, 本文以构建对比实验方法, 采用四个 T2VR 任务中先进的检索模型。其中, 包括基于双编码器的 DE 模型^[20]、以及基于文本编码器组合的 SEA 模型^[19], 上述两个基线模型与本文 TVRVCML 模型的方法相似, 属于面向 T2VR 任务中基于多个公共空间学习的方法。另外, 本文还选取 T2VR 任务中广泛使用的两个基线模型, 一个是基于多模态特征融合的 CE 模型^[44], 利用多“专家”编码器来处理视频中特定模态信息。另一个是基于文本视频联合表示的 W2VV++模型^[12]。通过将上述四个模型作为基线与 TVRVCML 模型形成对比, 并以 R@K、MdR 和 mAP 为评价指标, 对这五个模型最终检索效果进行对比分析, 旨在验证本文提出的 TVRVCML 模型设计的合理性和优越性。

下面将详细介绍四个基线模型设计特点。

(1) DE 模型

2022 年, Dong 等人提出一种新颖的双编码模型 DE, 利用初级编码器与双向 GRU 网络结合方法, 对视频和查询文本进行多级编码。此外, DE 模型在构建出语义公共空间的基础上, 还构建出概念公共空间。通过在两种类型公共空间中进行特征匹配和相似度计算, 同时提升了模型检索性能和可解释性。

(2) SEA 模型

2021 年, Li 等人提出一种文本编码器组合框架 SEA, 通过将多种不同类型文本编码器进行多种组合, 并将多种编码器获得的文本特征向量与视频特征向量在多个公共空间进行多种特征匹配, 取得了良好检索性能。值得说明的是, 与 SEA 模型进行对比实验时, 由于 SEA 模型使用了多种文本编码器组合, 本文选取其在 MSVD 数据集上模型性能表现最好的 {BoW, W2V, BERT} 的组合作为模型固定搭配。

(3) CE 模型

2019 年, Liu 等人提出一种联合专家模型 CE, 利用多种“专家”编码器, 对视频中图像、动作和音频等信息进行充分挖掘, 每种专家编码器只负责视频特定模态的特征表示。随后将多种专家特征利用门控机制进行特征融合, 并将最终的视频特征表示与文本特征表示一并映射到一个公共空间中进行特征匹配和相似度计算, 是 T2VR 任务中最常使用基线方法之一。

(4) W2VV++模型

2019 年, Li 等人提出一种词到视觉向量模型 W2VV++, 它通过将多个文本特征向量的输出连接到一个长特征向量中来组合多种句子编码器, 然后利用全连接层将文本连接向量和视频特征向量映射到公共空间中。该模型同样是 T2VR 任务中广泛使用的基线模型之一。

3.4.2 对比实验分析

通过将 TVRVCML 模型与上述四个基线模型分别在三个数据集上进行对比实验，并以相同评价指标作为模型性能标准。对比实验具体结果如表 3.5-3.7 所示。

表 3.5 MSVD 数据集上对比实验结果

Table 3.5 Results of comparative experiments on the MSVD dataset

模型	MSVD 数据集				
	R@1	R@5	R@10	MdR	mAP
DE	23.4	53.2	65.7	4	37.9
SEA{BoW,W2V,BERT}	24.6	54.3	67.6	4	38.7
CE	21.5	51.1	65.2	5	36.8
W2VV++	22.4	51.6	64.8	5	36.1
TVRVCML (本文)	25.7	55.4	69.2	4	39.7

表 3.6 MSR-VTT 数据集上对比实验结果

Table 3.6 Results of comparative experiments on the MSR-VTT dataset

模型	MSR-VTT 数据集				
	R@1	R@5	R@10	MdR	mAP
DE	11.6	30.3	41.3	17	21.2
SEA{BoW,W2V,BERT}	13.1	33.4	45.0	14	23.3
CE	10.0	29.0	41.2	16	22.1
W2VV++	11.1	29.6	40.5	18	20.6
TVRVCML (本文)	13.7	33.8	45.6	13	23.9

表 3.7 TGIF 数据集上对比实验结果

Table 3.7 Results of comparative experiments on the TGIF dataset

模型	TGIF 数据集				
	R@1	R@5	R@10	MdR	mAP
DE	11.3	24.7	32.5	37	18.3
SEA{BoW,W2V,BERT}	10.7	24.4	31.9	37	17.9
CE	10.2	23.5	30.2	44	16.6
W2VV++	9.4	22.3	29.8	48	16.2
TVRVCML (本文)	10.9	24.7	32.3	37	18.1

从实验结果中可以看出，本文提出的 TVRVCML 在 MSVD 数据集和 MSR-VTT 数据集上的三大性能指标均达到最优。与表现最佳基线模型相比。在 MSVD 数据集中，R@1 值提高 4.47%，R@5 值提高 2.03%，R@10 值提高 2.37%，MdR 值一致，

mAP 值提高 2.58%。同时，在 MSR-VTT 数据集中，R@1 值提高 4.58%，R@5 值提高 1.2%，R@10 值提高 1.33%，MdR 值降低 7.14%，mAP 值提高 2.58%。另外，在 TGIF 数据集上 TVRVCML 模型没有达到最优表现，仅次于 DE 模型，由于该数据集中可能存在噪声或异常值，影响了模型学习。但相较于其他三个基线模型均有明显效果提升，验证了本文 TVRVCML 模型设计的合理性和有效性。

此外，由于前 K 项召回率（R@K）和平均精度（mAP）的值越大代表模型检索性能越好，而中位数排序（MdR）的值越小代表模型性能越好。因此，本文以柱状图方式分别呈现以上两类性能指标在三个数据集上对比实验结果，能更加直观地看出 TVRVCML 模型提升效果。前 K 项召回率对比实验结果如图 3.2 所示。




图 3.2 前 K 项召回率对比实验结果

Figure 3.2 Comparison experiment results of recall rates for the first K items

平均精度 mAP 对比实验结果如图 3.3 所示。




图 3.3 mAP 对比实验结果

Figure 3.3 Comparative experimental results of mAP

中位数排序 MdR 对比实验结果如图 3.4 所示。




图 3.4 MdR 对比实验结果

Figure 3.4 Comparative experimental results of MdR

3.4.3 消融实验分析

为了验证 TVRVCML 模型中两个创新模块的有效性，即多空间构建层中同模态公共空间模块 SMP 和多空间融合层中自注意力机制模块 SA。保持其他实验条件不变条件下，在 MSVD 数据集上通过替换和修改上述模块分析各个模块作用，消融实验具体设置说明如下所示。

(1) w/o SMP: 去除 TVRVCML 模型中查询文本与视频字幕间 1 个同模态公共空间，仅保留 3 个跨模态公共空间和自注意力机制，以验证同模态匹配与跨模态匹配相互结合对于检索性能提升情况。

(2) w/o SA: 去除 TVRVCML 模型中为多空间权重分配的自注意力机制模块，将多个公共空间中特征匹配结果替换成简单求和取平均策略，仅保留查询文本与视频字幕间同模态公共空间，验证 TVRVCML 模型中基于自注意力机制模块多空间融合策略对于检索性能提升情况。

(3) FULL: 完整版 TVRVCML 模型，用于对比消融实验结果。

表 3.8 MSVD 数据集上消融实验具体结果

Table 3.8 Specific results of ablation experiments on the MSVD dataset

模型	MSVD 数据集				
	R@1	R@5	R@10	MdR	mAP
w/o SMP	24.4	54.5	67.7	5	38.8
w/o SA	25.2	54.9	68.6	4	39.2
FULL	25.7	55.4	69.2	4	39.7

通过消融实验结果可以看出：首先，同模态公共空间 SMP 模块和自注意力机制 SA 模块对于模型检索性能均存在不同程度上的正向促进作用。其次，去除 SMP 模块后，模型检索前 K 项召回率性能的降幅较大，为 1.62%~5.06%，说明同模态空间模块贡献更大。此外，本文通过贡献度的方式来说明 TVRVCML 模型创新模块对于提升检索性能作用。贡献度计算方法如公式 (3-16) 所示。

$$\text{贡献度} = |\text{Relative Improve Metric}| \times 1000 \quad (3-16)$$

同模态公共空间 SMP 模块和自注意力机制 SA 模块对于性能指标 R@1、R@5、R@10、MdR 和 mAP 贡献度如图 3.5 所示。




图 3.5 SMP 和 SA 模块贡献度

Figure 3.5 Contribution of SMP and SA modules

3.4.4 超参敏感性实验分析

为了验证本章模型实验参数有效性，在 MSVD 数据集上对公共空间损失函数中裕度参数 α 进行超参敏感性实验。参数 α 通常是一个固定常数，用于控制公共空间中正负样本之间间隔。对于 T2VR 任务中基于公共空间学习的方法来说，参数 α 的选取直接影响模型检索性能，过小的裕度参数可能导致模型过度拟合，而过大的裕度参数可能导致模型学习无效。本文将参数 α 分别取值为 0.05、0.1、0.15、0.2 和 0.25，并以平均精度 mAP 为评价指标，通过改变裕度参数 α 取值，观察其对于 TVRVCML 模型检索性能影响变化。如表 3.9 所示，

表 3.9 MSVD 数据集上超参敏感性实验具体结果

Table 3.9 Specific results of margin parameter experiments on the MSVD dataset

TVRVCML 模型	MSVD 数据集				
	R@1	R@5	R@10	MdR	mAP
$\alpha=0.05$	24.6	54.5	67.8	5	38.6
$\alpha=0.1$	25.0	54.7	68.4	4	39.1
$\alpha=0.15$	25.3	55.2	68.9	4	39.4
$\alpha=0.2$	25.7	55.4	69.2	4	39.7
$\alpha=0.25$	25.5	55.1	68.7	4	39.3


图 3.6 裕度参数 α 取值对于检索性能影响

Figure 3.6 The impact of margin parameter value on retrieval performance

由图 3.6 可知,随着裕度参数 α 不断变大,TVRVCML 模型的 mAP 指标表现呈现出先递增后下降趋势,并在 $\alpha=0.2$ 时取得最优表现,这证明了本文对公共空间损失函数中裕度参数 α 取值的合理性,使得模型更容易学习到一个表现优秀的公共空间,降低多模态之间的语义鸿沟,进而优化检索性能。

3.5 本章小节

本章首先介绍了 TVRVCML 模型设计背景以引出创新动机。接着说明了其整体结构,并按照模型层次关系详细介绍每层结构设计。为验证 TVRVCML 模型性能,本章接着从数据集描述和评价指标入手,同时说明了实验运行环境和模型参数设置。最后,通过引入基线模型并构建对比实验,接着在 MSVD 数据集上进行消融实验和模型超参数敏感性实验,并对实验结果进行深入分析,验证了本文提出的 TVRVCML 模型的有效性和优越性。

4 森林疗养课程培训系统研建

针对林学会森林疗养分会亟需实现森林疗养师在线培训实际需求,本章详细介绍森林疗养课程培训系统需求分析、架构设计、数据库设计以及关键功能模块详细设计与实现。本系统核心目标是为参与森林疗养培训学员提供优质的在线培训服务,同时为系统管理员提供资源管理、课程管理和班课管理等业务功能。最后引入文本视频跨模态检索功能,帮助系统用户高效、准确完成课程视频检索,提高培训质量和效果。

4.1 系统需求分析

森林疗养课程培训系统作为一种在线课程培训平台,旨在促进参与森林疗养培训学员对培训课程深入理解和学习,从而提升森林疗养师的培训质量和专业水平。另外,该系统不仅要为学员提供便捷的学习途径,还应向系统管理员提供一系列功能。例如,资源管理、课程管理和班课管理等。本章节主要针对森林疗养课程培训系统进行需求分析,以明确系统的实现目标和主要功能。接下来,将从系统的功能性需求和非功能性需求两个角度进行详细阐述。

4.1.1 功能性需求

本文研建该系统的功能性需求主要来源于以下三个方面。第一,林学会森林疗养分会迫切需要对疗养师进行在线培训,以适应行业发展需求。第二,由于森林疗养在国内处于兴起阶段,专门针对培训森林疗养师这一新兴职业的在线课程培训系统相对匮乏。第三,由于森林疗养相关课程视频数量繁多、内容复杂,现有的 Web 系统或小程序中用户难以高效准确地检索到目标课程视频。因此,研建一个功能完善的森林疗养课程培训系统具有重要现实意义。

本系统主要任务是提供在线课程培训服务,其设计目标是帮助参与森林疗养培训的学员更好地理解和学习培训课程,提升森林疗养师培训质量和水平。以在线培训为核心业务目标,系统应具备资源管理、课程管理、班课管理、学员管理、选课、支付和课程学习等主要功能。基于需求分析和业务划分实际情况,确定相应用户角色,进而得出系统整体用例图。如图 4.1 所示。

本系统主要用户是系统管理员和参与培训的学员用户这两种角色。为了明确用户角色和权限,本系统应采用分端设计模式,以提升用户体验和管理效率。其中,系统管理员负责管理和维护系统,包括班课管理、课程管理、资源管理以及学员管理等。而学员在注册登录系统后,能够实现选课、支付费用、检索课程和观看课程学习等。同时,学员用户应能够更加便捷地获取所需课程视频资源,提升培训质量和学习效果。管理员应能够有效管理和维护系统稳定运行,提高管理效率。

根据上述需求,下面将对该系统功能性需求做更详尽描述。




图 4.1 系统整体用例图

Figure 4.1 Overall user case diagram of the system

管理员端：

(1) 资源管理

为了满足学员多样化学习需求,系统应支持上传 PDF 和视频两种类型课程资源。同时,为了避免系统内存空间和带宽过度占用,以及保障学员观看课程视频学习时的良好播放体验,管理员在上传资源时,应能够限制上传资源体积大小。另外,为方便管理员在繁杂视频资源中快速找到目标课程视频,系统应具备良好的视频检索性能。

(2) 课程管理

首先,管理员应具备课程搜索功能,以便在众多视频中准确、高效地检索到所需课程视频。此外,管理员应能够为课程绑定相关视频或 PDF 资源,并能对课程信息进行编辑以及删除等操作。

(3) 班课管理

完成资源与课程的绑定之后,管理员应能够为班课绑定相应课程。同时,还应该具备查看班课详情信息、编辑班课、删除班课以及查看班课下报名学员功能,此外,应该支持为班课批量导入学员等操作。

(4) 学员管理

管理员需要查询系统中所有注册用户能力,以便查看和管理学员用户。同时,应支持按照姓名快速查找用户,以便快速寻找目标学院。此外,为了应对用户可能忘记密码的问题,管理员还应具备重置密码功能。

学员端：

（1）个人信息管理

学员在完成系统注册和登录后，系统应提供个人信息管理功能。该功能应该支持学员对个人的用户名、联系电话、电子邮件、工作单位以及居住地等信息进行修改。此外，为保障学员用户的安全，还应设置密码修改功能。

（2）学员选课

在学员端的系统页面上，应展示该学员在当前时间下所有可供选择的班课详情，以便学员进行选课操作。同时，由于课程培训系统中视频资源繁多，学员在不清楚具体课程名称、课程分类等信息情况下，系统应提供高效准确的课程视频检索服务。

（3）班课费用支付

学员在选择班课后，应进入班课费用支付流程。系统应明确向学员展示系统支持的支付方式、支付流程以及支付金额等信息。为防止资金损失，应采用事务处理订单和支付状态，确保支付过程中数据更新保持一致性。同时，要设计合理异常处理措施，如支付超时和支付失败等情况，以提高系统的可靠性和稳定性。

（4）观看课程学习

完成班课选择和支付流程之后，学员能够根据班课设定的开课时间和学习周期，灵活安排时间进行课程观看和学习。为了保障学员学习质量和效果，系统应确保课程视频播放的稳定性和流畅性，避免出现卡顿、中断等问题。同时，系统还应为学员提供详细的学习进度信息，包括已观看视频时长、完成课程章节等，以便学员随时了解个人学习进度。

4.1.2 非功能性需求

为了保障森林疗养课程培训系统在投入使用后的可靠性和稳定性，本小节将着重阐述软件系统的非功能性需求。森林疗养课程培训系统主要服务对象是参与培训的广大学员，可能存在大量学员同时在线观看课程视频或同时进行课程支付等情况。因此，系统实际运行效果和用户体验显得尤为重要。除了完成系统基本功能之外，本系统还需要充分考虑非功能性需求，包括系统性能、安全性、易用性、兼容性以及可扩展性等方面特性。接下来将展开详细介绍。

（1）性能需求

在森林疗养课程培训系统中，性能需求主要包括以下两个方面：一是在管理员端页面上传课程资源时，应对视频和 PDF 资源体积进行限制，避免系统存储空间过度占用和传输带宽浪费。二是在学员端页面需要应对大量学员同时在线观看课程视频或同时进行班课支付等情况，为此系统应具备良好的多用户并发处理能力，支持流畅的视频流媒体传输，减少缓冲和卡顿现象。同时，还需要应用服务器负载均衡、数据库优化以及缓存等技术，确保系统能够及时响应用户请求。

（2）安全性需求

为保障系统数据安全和用户信息隐私，该系统应该进行以下安全性设置：首先，设定用户权限，只有管理员拥有高级权限，以确保系统的管理和操作受到严格控制。此外，设定系统用户身份验证和授权，使用唯一的令牌 `token` 标识作为用户经过系统验证后的身份标识。同时，密码存储时，采用加密盐值 `salt` 字段与用户密码结合存储。

（3）易用性需求

在系统易用性需求方面，需要确保文字图片排版合理、页面结构布局清晰，符合大多数用户习惯。并且业务处理流程应简洁明了，易于用户理解和操作。此外，系统还应具备良好的交互性和反馈机制，及时响应用户操作并提供清晰提示信息，以提升用户体验。

（4）兼容性需求

兼容性是评估软件系统质量的关键指标之一。对于森林疗养课程培训系统这样的 Web 系统来说，需要具备良好的兼容性，以支持市面上主流的软硬件设备。具体来说，应兼容各种不同的浏览器、操作系统以及设备机型，以确保本系统在各种主流环境下能够正常运行。

（5）可扩展性需求

系统可扩展性需求应使用灵活的架构设计。例如，采用模块化设计，便于对单个功能模块进行修改或扩展新功能，而不影响整体系统。同时，数据库结构也应该具备可扩展性，方便容纳更多的用户、资源和课程等数据。这样一来，可以为系统的后续维护和优化提供有力支持。

4.2 系统概要设计

基于系统需求分析，本章节将详细论述系统的架构设计、功能模块设计以及数据库设计，为系统的详细设计与实现奠定坚实基础。

4.2.1 系统架构设计

本系统采用分层架构设计，每个层次都有特定的职责和功能，层次之间通过定义接口进行交互。合理的层次划分可以提高系统的开发效率和可扩展性，并降低系统的复杂度，使得系统能够更好地应对未来的复杂业务和变化。

同时，本系统基于 B/S 架构，采用前后端分离的设计开发模式，其通过 API 接口实现前后端数据交互。系统前端主要采用 Vue.js 框架和 Element UI 组件库进行开发，模块化框架思想有利于快速搭建页面，同时提升相似模块的代码复用性。此外，采用 Webpack 打包工具将页面所需静态文件打包为 Vue.js 框架组件，最后通过浏览器渲染页面并展示结果。后端采用 Spring Boot 框架进行开发，通过将后端划分为 Controller 层、Service 层和 Mapper 层来处理业务逻辑。最后，使用 MySQL 数据库来实现数据

的存储和管理。

森林疗养课程培训系统架构设计图如图 4.2 所示。




图 4.2 系统架构设计

Figure 4.2 Design of architecture of the system

(1) 访问层

作为系统入口，用户在浏览器上输入森林疗养课程培训系统正确的网址域名后，即可访问森林疗养课程培训系统。

(2) 展示层

展示层主要负责向用户展示系统界面和处理用户输入。本系统的展示层采用 Vue.js 框架，并结合 Element UI 组件库中提供的现成组件对前端界面进行渲染，实现文字图片排版合理、页面结构布局清晰的系统界面。

（3）控制层

控制层负责接收用户请求和调用业务逻辑，是用户与系统业务逻辑之间的桥梁。根据用户请求类型和参数，将其分发到相应业务逻辑文件进行处理。同时，控制层将处理结果传递给前端展示层，生成相应视图或结果呈现给系统用户。

（4）业务逻辑层

业务逻辑层分为接口和实现类两种类型文件，负责将控制层接口涉及的业务功能进行实现。同时，负责与数据访问层进行数据传递和转换。

（5）数据访问层

数据访问层负责与数据库进行交互，包括各种 SQL 语句，确保数据操作原子性、一致性以及隔离性，保证数据传输稳定。

（6）数据库

本系统采用关系型数据库 MySQL 作为数据存储和管理工具，并通过主键索引、创建主从数据库等操作，缓解数据慢查询问题。

4.2.2 系统功能模块设计

通过对系统需求深入分析和理解，本文将森林疗养课程培训系统设计为管理员端和学员端两个部分。为了便于系统开发，本文选择模块化设计，以提高系统可维护性和扩展性。系统功能模块图如图 4.3 所示。接下来将展开详细介绍。




图 4.3 系统功能模块图

Figure 4.3 Diagram of system function module

管理员端：

（1）资源管理模块

为了满足培训学员不同的学习需求，资源管理支持上传视频和 PDF 两种类型的资源。该模块还提供一系列操作功能。具体来说，管理员能够根据资源与课程的绑定情况进行筛选，迅速定位并处理所需资源。同时，支持添加新资源，确保培训内容的及时更新与拓展。对于过期资源和未绑定课程资源，管理员可以进行删除操作，从而释放系统存储空间，保持系统整洁高效。此外，该模块具备查看资源详情和编辑资源简介功能，使管理员能够方便地了解和管理资源具体内容。

（2）课程管理模块

在课程管理模块中，为了提高管理员课程管理效率，系统提供了按课程名称查询目标课程功能和一键展示所有课程功能。同时设置添加新课程功能，以及查看课程下绑定资源信息和未绑定课程资源等功能。

（3）班课管理模块

在该模块中，管理员可根据班课报名状态和开课状态进行筛选，同时添加新班课。管理员还可以查看班课详细信息，包括该班课下所有课程内容。另外，还拥有编辑和删除班课权限，并且能够给未开课的班课绑定相应课程。上述功能的设计与实现，为高效管理班课信息提供了有力支持，进而确保培训顺利开展。

（4）学员管理模块

在学员管理模块中，管理员可以根据学员姓名进行精确查询，快速定位特定学员信息，同时支持一键展示全部学员功能。为了方便学员在忘记密码时，能够重新获得系统访问权限，系统授予管理员重置学员登录密码功能。此外，管理员还能够查看班课下报名学员详情，并能够通过身份证号码实现班课学员批量导入。

学员端：

（1）个人信息管理模块

学员在完成系统注册和登录后，系统提供个人信息管理功能。该功能支持学员对个人的用户名、联系电话、电子邮件、工作以及居住地等信息进行修改。此外，为了保障学员用户信息安全，还设置了密码修改功能。

（2）学员选课模块

学员分为初级、中级和高级疗养师，系统会展示在当前时间下所有可供选择班课详情，以便学员进行选课操作。同时，学员可以查看班课下课程详细信息，确保学员对所选班课信息有明确的了解。

（3）班课费用支付模块

学员在选择班课后，进入班课费用支付流程。系统会明确向学员展示支持的支付方式、支付流程以及支付金额等信息。同时，学员在班课支付成功后，能够在系统中查看相应订单信息。

(4) 观看课程学习模块

完成班课选择和支付流程后,学员能够根据班课设定开课时间和学习周期,灵活安排时间进行班课下课程观看和学习。同时,系统还为学员提供详细的学习进度信息,包括已观看的视频时长、课程章节完成度等信息,以百分比形式展示给学员用户,以方便学员随时了解个人学习进度。

4.2.3 数据库设计

本系统使用 MySQL 数据库来存储和管理相关数据。本章节将依据 E-R 图对系统涉及的实体进行抽象。该系统主要包括班课、课程、视频资源、PDF 资源、学员用户和订单等七个实体。在识别出系统中各个实体、实体属性及其相互关系后,得到系统 E-R 图如图 4.4 所示。




图 4.4 系统 E-R 图

Figure 4.4 E-R diagram of the system

根据上述分析以及 E-R 图中所呈现出的实体属性和实体关系,以下以数据库表的形式,说明森林疗养课程培训系统数据库中数据组织方式和关系,本系统主要涉及 10 张数据库表。以下是各表详细设计。

(1) 班课信息表。如表 4.1 所示, 该表用于存储本系统中相关班课的信息, 包括班课名称、班课简介、班课类型、开办年份、开课时间、结课时间、人数限定以及班课价格等内容, 该表主键为自动递增的 ID。

表 4.1 班课信息表

Table 4.1 The database table of class information

字段名	数据类型	长度	描述	主键	允许为空
class_id	varchar	255	班课 ID	是	否
name	varchar	50	班课名称	否	是
introduction	varchar	255	班课简介	否	是
type	char	1	班课类型	否	否
year	data	—	开办年份	否	是
enroll_begin_time	datetime	—	开始报名时间	否	是
enroll_end_time	datetime	—	截止报名时间	否	是
class_begin_time	datetime	—	开课时间	否	是
class_end_time	datetime	—	结课时间	否	是
number_limit	int	11	人数限定	否	是
complete_rate	int	11	完成率下限	否	是
price	decimal	7	班课价格	否	是
gmt_created	datetime	—	创建时间	否	是
gmt_modified	datetime	—	修改时间	否	是

(2) 课程信息表。如表 4.2 所示, 该表用于存储本系统中相关课程的信息, 包括课程名称、课程简介以及课程总学时等内容, 该表主键为自动递增的 ID。

表 4.2 课程信息表

Table 4.2 The database table of course information

字段名	数据类型	长度	描述	主键	允许为空
course_id	varchar	255	课程 ID	是	否
name	varchar	30	课程名称	否	是
introduction	varchar	255	课程简介	否	是
course_hour	int	11	课程总学时	否	是
gmt_created	datetime	—	创建时间	否	是
gmt_modified	datetime	—	修改时间	否	是

(3) 视频资源信息表。如表 4.3 所示, 该表用于存储本系统相关视频资源信息, 包括视频名称、视频简介、视频类型、描述图片、所属课程 ID 以及视频时长等内容, 该表主键为自动递增的 ID。

表 4.3 视频资源信息表

Table 4.3 The database table of video resource information

字段名	数据类型	长度	描述	主键	允许为空
video_id	varchar	255	视频 ID	是	否
name	varchar	255	视频名称	否	是
introduction	varchar	255	视频简介	否	是
file_type	varchar	255	视频类型	否	是
picture_location	varchar	255	描述图片	否	是
deleted_flag	char	1	是否被删除	否	是
course_id	varchar	255	所属课程的 ID	否	是
video_time	int	50	视频时长	否	是
gmt_created	datetime	—	创建时间	否	是
gmt_modified	datetime	—	修改时间	否	是

(4) PDF 资源信息表。如表 4.4 所示, 该表用于存储本系统相关 PDF 资源信息, 包括 PDF 名称、PDF 简介、描述图片、类型、所属课程 ID 以及要求观看时长等内容, 该表主键为自动递增的 ID。

表 4.4 PDF 资源信息表

Table 4.4 The database table of pdf resource information

字段名	数据类型	长度	描述	主键	允许为空
id	varchar	255	PDF 资源 ID	是	否
name	varchar	255	PDF 名称	否	是
introduction	varchar	255	PDF 简介	否	是
file_type	varchar	255	文件类型	否	是
picture_location	varchar	255	描述图片	否	是
course_id	varchar	255	所属课程的 ID	否	是
pdf_time	int	10	要求观看时长	否	是
gmt_created	datetime	—	创建时间	否	是
gmt_modified	datetime	—	修改时间	否	是

(5) 用户信息表。如表 4.5 所示, 该表用于存储本系统中相关用户的信息, 包括用户姓名、身份证、登录密码、手机号、用户类型、工作单位、微信号以及联系地址等内容, 该表主键为自动递增的 ID。

表 4.5 用户信息表

Table 4.5 The database table of user information

字段名	数据类型	长度	描述	主键	允许为空
user_id	varchar	255	用户 ID	是	否
name	varchar	255	用户姓名	否	是
id_number	varchar	18	用户身份证	否	否
password	varchar	255	登录密码	否	否
phone	varchar	11	手机号	否	是
token	varchar	255	用户身份令牌	否	否
salt	varchar	255	密码加密盐值	否	否
type	tinyint	4	用户类型	否	是
job_address	varchar	50	工作单位	否	是
job	varchar	50	目前从事行业	否	是
address	varchar	100	联系地址	否	是
wechat	varchar	30	微信号	否	是
gmt_created	datetime	—	创建时间	否	是
gmt_modified	datetime	—	修改时间	否	是

(6) 学员所属班课信息表。如表 4.6 所示, 该表用于存储本系统中班课下学员的相关信息, 包括班课 ID、学员 ID、班课支付状态以及学习状态等内容, 该表的主键为自动递增的 ID。

表 4.6 学员所属班课信息表

Table 4.6 The database table of user_class information

字段名	数据类型	长度	描述	主键	允许为空
id	varchar	255	ID	是	否
class_id	varchar	255	班课 ID	否	否
user_id	varchar	255	用户 ID	否	否
pay_state	tinyint	10	班课支付状态	否	否
study_state	tinyint	10	班课学习状态	否	是

(7) 课程所属班课信息表。如表 4.7 所示, 该表用于存储本系统中班课下相关课程的信息, 包括班课 ID、课程 ID 以及创建时间等内容, 该表主键为自动递增的 ID。

表 4.7 课程所属班课信息表

Table 4.7 The database table of class_course information

字段名	数据类型	长度	描述	主键	允许为空
id	varchar	255	ID	是	否
class_id	varchar	255	班课 ID	否	否
course_id	varchar	255	课程 ID	否	否

(8) 用户学习视频资源信息表。如表 4.8 所示, 该表用于存储本系统中用户学习视频资源的相关信息, 包括用户 ID、视频 ID、学习时长以及完成情况等内容, 该表主键为自动递增的 ID。

表 4.8 用户学习视频资源信息表

Table 4.8 The database table of user_video information

字段名	数据类型	长度	描述	主键	允许为空
id	varchar	255	ID	是	否
user_id	varchar	255	用户 ID	否	否
video_id	varchar	255	视频 ID	否	否
duration	int	11	学习时长	否	是
state	char	1	完成情况	否	是

(9) 用户学习 PDF 资源信息表。如表 4.9 所示, 该表用于存储本系统中用户学习 PDF 资源的相关信息, 包括用户 ID、PDF 的 ID、学习时长以及完成情况等内容, 该表主键为自动递增的 ID。

表 4.9 用户学习 PDF 资源信息表

Table 4.9 The database table of user_pdf information

字段名	数据类型	长度	描述	主键	允许为空
id	varchar	255	ID	是	否
user_id	varchar	255	用户 ID	否	否
duration	int	11	学习时长	否	是
state	char	1	完成情况	否	是

(10) 全部订单信息表。如表 4.10 所示, 该表用于存储本系统中用户购买班课的全部订单信息, 包括订单号、用户 ID、班课 ID、订单名称、订单总金额、支付宝交易号以及收款账户对应的支付宝唯一用户号等内容, 该表主键为订单号 ID。

表 4.10 全部订单信息表

Table 4.10 The database table of order_all information

字段名	数据类型	长度	描述	主键	允许为空
out_trade_no	varchar	255	订单号 ID	是	否
user_id	varchar	255	用户 ID	否	否
class_id	varchar	255	班课 ID	否	否
subject	varchar	255	订单名称	否	否
body	varchar	255	商品描述	否	是
charset	varchar	255	请求使用的编码格式	否	是
method	varchar	255	接口名称	否	是
total_amount	decimal	65	订单总金额	否	是
sign	text	—	请求参数的签名串	否	是
trade_no	varchar	255	支付宝交易号	否	是
auth_app_id	varchar	255	支付宝的开发者应用 ID	否	是
version	varchar	255	调用的接口版本	否	是
app_id	varchar	255	支付宝分配的应用 ID	否	是
sign_type	varchar	255	生成签名的算法类型	否	是
seller_id	varchar	255	收款账户对应的用户号	否	是
timestamp	timestamp	6	时间戳	否	是
gmt_created	datetime	—	创建时间	否	是
gmt_modified	datetime	—	修改时间	否	是

综上所述, 森林疗养课程培训系统包括以上 10 张核心数据库表, 其中主要包括班课、课程、视频资源、PDF 资源、学员用户和订单等七个实体。通过数据库表设计, 一方面能够有效地简化系统开发难度, 另一方面对于组织和管理数据具有重要意义, 为系统高效运行和培训质量保障提供了坚实基础。

4.3 系统详细设计与实现

森林疗养课程培训系统搭建主要采用 Vue.js 和 Spring Boot 前后端分离开发模式。基于前两章节对系统需求分析和概要设计的介绍，本节将着重从系统详细设计与实现层面进行阐释。通过活动图、时序图、类图以及文字说明相结合的方式，详细介绍本系统关键功能模块实现步骤，并进行界面展示。

4.3.1 资源管理模块详细设计与实现

(1) 资源管理模块的详细设计

在本系统管理员端中，其核心功能是针对资源、课程以及班课三者管理，管理员合理的操作顺序为：首先将视频和 PDF 类型资源进行上传，其次将资源与课程绑定，最后再将课程与班课绑定，以班课的形式呈现给学员用户。因此，本文首先介绍资源管理模块的详细设计与实现，关键功能模块的核心流程活动图如图 4.5 所示。




图 4.5 核心流程活动图

Figure 4.5 Core process Activity diagram

在资源管理模块中，其主要功能包括添加资源、筛选资源类型、查看资源详情、检索视频资源以及删除资源等。为了满足学员用户不同的学习需求，本系统支持视频和 PDF 两种类型资源。接下来以视频资源类型为例，阐述资源管理模块详细设计。

首先,管理员点击视频资源管理模块,系统调用/video/allVideo/{current}接口,定位到控制层 VideoController 中 getAllVideo 方法,并请求转发到业务逻辑层 IVideoService 服务中调用 videoMapper 中 selectPage 方法,以获取所有视频资源。其次,由于视频资源繁杂,同时系统后续视频资源不断增加,为快速定位目标课程视频,系统使用 TVRVCML 模型作为底层检索算法,并将检索结果以 JSON 格式返回前端进行页面展示,提高视频资源管理效率。同时,能够根据资源类型进行筛选,选取未绑定课程资源时,调用 video/getVideoNotCourse/{current}接口,将 deleted_flag 字段修改为未绑定课程标识,并调用 videoMapper 的 selectPage 方法,获取所有未绑定课程的视频资源。视频资源管理时序图如图 4.6 所示。




图 4.6 视频资源管理时序图

Figure 4.6 Video resource management Sequence diagram

另外,管理员点击编辑按钮,系统会调用/video/updateIntroduction 接口,实现对视频简介信息修改。点击添加资源按钮,系统调用/video/uploadFile 接口,当填写课程学习时长并点击确定后,视频上传至服务器并返回视频链接。同时系统调用/video/add 接口,实现对视频资源添加。点击删除资源按钮,前端首先校验当前视频资源的 deleted_flag 字段,如果为已绑定课程标识,即当前资源已与课程进行了绑定,则视频资源无法删除。除了视频类型资源之外,系统还提供 PDF 类型资源,所实现功能与视频资源一致。

(2) 资源管理模块的实现

目前森林疗养课程培训系统已开发测试完毕并配置在阿里云服务器中, 视频资源管理页面如图 4.7 所示。




图 4.7 视频资源管理页面

Figure 4.7 Video resource management page

同时, 系统支持 PDF 类型资源管理, PDF 资源管理页面如图 4.8 所示。




图 4.8 PDF 资源管理页面

Figure 4.8 PDF resource management page

4.3.2 课程管理模块详细设计与实现

(1) 课程管理模块的详细设计

课程管理模块作为资源管理和班课管理之间桥梁。管理员合理地操作顺序应该是首先上传课程所需资源，接着将资源绑定到课程中，最后再将一个或多个课程绑定到班课上。**CourseController** 类主要负责解析与课程管理相关的请求，核验成功后再转交给 **ICourseService** 接口的实现类 **ICourseServiceImpl**，执行具体业务逻辑代码，并通过 **ClassCourseController** 类与 **ClassController** 类相关联，在处理业务逻辑同时调用 **ClassMapper**、**CourseMapper** 中方法进行数据库操作。因此，在介绍完资源管理模块的基础上，选用类图方式说明课程与班课之间关系。课程管理类图如图 4.9 所示。




图 4.9 课程管理类图

Figure 4.9 Course management Class diagram

管理员点击课程管理功能，系统调用 `/course/getAllCourse/{current}` 接口，定位到 **CourseController** 中 `getAllCourse` 方法，获取所有课程信息。同时，系统支持按照课程关键信息进行模糊查询。点击立即创建按钮，调用 `/course/addCourse` 接口，课程信息由 **Course** 对象封装，实现添加课程功能。编辑课程支持对课程名、课程介绍、课程学时和课程类型的修改，调用 `/course/updateCourse` 接口，实现修改课程信息功能。每门课程可以绑定视频或 PDF 两种类型资源，点击绑定资源按钮，系统调用 `/class-`

course/getClassWithCourse 接口，获取系统当前所有未绑定课程的视频资源。在选择资源后点击绑定，调用/course/bindVideo/接口，实现课程对视频资源的绑定。PDF 类型资源与视频类型资源绑定课程的逻辑一致。

（2）课程管理模块的实现

课程管理页面如图 4.10 所示。




图 4.10 课程管理页面

Figure 4.10 Course management page

4.3.3 班课管理模块详细设计与实现

（1）班课管理模块详细设计

班课管理模块作为管理员端和学员端桥梁，学员在完成注册登录后，即看到班课信息。管理员点击班课管理功能，系统调用/class/allClass/{current}接口，定位到ClassController中getAllClass方法，获取所有班课信息。同时，系统支持根据班课类型筛选，点击不同班课类型，系统将根据班课类型字段classType获取符合筛选条件的班课信息。点击添加班课按钮，填写班课的班课名、班课简介、班课限制人数等必要信息，系统调用/class/addClass接口，实现添加班课功能。点击编辑、删除和绑定课程功能时，系统首先判断当前时间是否晚于班课开始时间，当该班课已经开课时，则无法进行上述三个功能。反之，点击编辑按钮时，系统调用/class/updateClass接口，后端使用Class对象封装修改的班课字段，实现编辑班课功能。点击删除按钮，系统调用/class/deleteClass/{classId}接口，根据班课id执行删除班课操作。点击绑定课程按钮，系统调用/class-course/addClassCourse接口，定位到ClassCourseController中

addClassCourse 方法,并请求转发到 IClassCourseService 服务,调用 classCourseMapper 中 insert 方法,实现班课绑定课程功能。班课管理时序图如图 4.11 所示。




图 4.11 班课管理时序图

Figure 4.11 Class management Sequence diagram

(2) 班课管理模块实现

班课管理页面如图 4.12 所示。




图 4.12 班课资源管理页面

Figure 4.12 Class management page

4.3.4 学员学习模块详细设计与实现

(1) 学员学习模块的详细设计

学员进入本系统后，系统调用/user/login 接口，后端使用 LoginDTO 对象来封装用户名和密码。同时，系统调用/user-class/getBoughtClasses/{userId}接口，定位到 UserClassController 中 getBoughtClasses 方法，并请求转发到 IUserClassService 服务，调用 ClassMapper 中 selecttBoughtClasses 方法，根据 useId 获取当前学员已购买班课信息。当用户点击已购买班课时，系统调用/class/getClassById 接口，获取当前所有购买班课的详细信息，包括班课名、开课时间、报名时间、班课价格等。同时，系统调用/course/getAllCourseByClassIdUserId 接口，获取当前登录用户下所有绑定课程信息。其中，字段 learnTimePre 为当前课程的完成率。点击课程视频时，系统调用/video/getVideo/{courseId}接口，获取该课程下所有视频类型资源。用户观看视频时，系统会调用/user-video/watchVideo/{videoId}/{currentTime}/{userId}接口，currentTime 字段为当前视频是否在播放标识，用户点击视频页面，可通过 currentTime 字段切换实现视频播放状态切换。学员学习时序图如图 4.13 所示。




图 4.13 学员学习时序图

Figure 4.13 User learning Sequence diagram

(2) 学员学习模块的实现

学习用户在完成班课购买之后,可查看班课详细信息,包括班课名称、开课时间以及课程学习完成率等。学员已购买班课页面如图 4.14 所示。




图 4.14 学员已购买班课页面

Figure 4.14 User bought class page

同时,学员可以观看学习课程相关资源,观看课程视频学习页面如图 4.15 所示。




图 4.15 观看课程视频学习页面

Figure 4.15 Watch course video learning page

4.4 系统测试

本章节将开展系统功能测试和非功能测试。功能测试将依据预先设计的测试用例进行，非功能测试则包括性能测试和兼容性测试两个部分，同时会列出测试结果并对其进行分析。

4.4.1 功能测试

功能测试核心目标是校验用户在使用系统各个功能模块时，是否能够按照需求分析设计阶段的预期结果正常运作。本小节将通过设计功能测试用例表，展示对于森林疗养课程培训系统核心功能模块所进行的测试。

如表 4.11 所示，该表是系统管理员在操作视频和 PDF 两类资源时的测试用例，其设计思路包括正向的增删改查操作以及逆向的资源大小和类型的限制。

表 4.11 资源管理模块测试用例表

Table 4.11 The test case table of the resource management module

编号	用例名	操作步骤	预期结果	实际结果
1	添加资源	点击添加资源按钮并填写信息	资源上传成功	通过
2	删除资源	点击删除资源按钮并确认删除	资源删除成功	通过
3	修改资源	点击编辑按钮并修改资源简介	简介修改成功	通过
4	检索视频资源	输入文本并点击查询	视频查询成功	通过
5	资源大小限制	上传视频资源时，选择文件体积大于 200M 的视频进行上传	资源上传失败，且页面出现用户提示 toast	通过
6	资源类型限制	上传视频资源时，选择后缀不是.avi 或.mp4 的视频进行上传	资源上传失败，且页面出现用户提示 toast	通过

如表 4.12 所示，该表是系统管理员在管理课程时的测试用例，其设计思路针对正向的课程绑定资源和逆向的开课时间等限制。

表 4.12 课程管理模块测试用例表

Table 4.12 The test case table of the course management module

编号	用例名	操作步骤	预期结果	实际结果
1	绑定课程资源	点击绑定资源按钮，分别为该课程绑定视频或 PDF 资源	资源顺利绑定课程	通过
2	课程开课时间	为已开课的课程绑定资源	资源绑定失败	通过

如表 4.13 所示, 该表是系统管理员在管理班课时的测试用例, 其设计思路包括正向的增删改查操作以及逆向的删除班课和班课绑定课程等限制。

表 4.13 班课管理模块测试用例表

Table 4.13 The test case table of the class management module

编号	用例名	操作步骤	预期结果	实际结果
1	添加班课	点击添加班课按钮并填写信息	班课创建成功	通过
2	填写时间限制	添加班课填写错误时间, 开始报名时间晚于结束报名时间,	班课创建失败	通过
3	填写长度限制	填写长度为 30 个汉字班课名	班课创建成功且班课名展示无截断现象	通过
4	删除班课	对已开课班课点击删除	班课不能删除	通过
5	班课绑定课程	对已开课班课绑定课程	班课不能绑定课程	通过

如表 4.14 所示, 该表是系统用户在选课时的测试用例, 其设计思路包括正向的增删改查操作以及逆向的资源大小和类型的限制。

表 4.14 用户选课模块测试用例表

Table 4.14 The test case table of the user class selection module

编号	用例名	操作步骤	预期结果	实际结果
1	用户登录系统	用户登录系统学员端	页面展示用户可选班课	通过
2	用户选择班课	点击页面中展示出来的班课	进入班课详情页面	通过
3	用户购买班课	在班课详情页, 点击购买按钮	进入订单支付页面	通过
4	用户完成购买	在订单支付页, 支付班课金额	班课支付成功	通过
5	查看班课详情	点击详情按钮	展示该班课下的所有课程, 并能查看课程资源	通过
6	查看课程资源	点击班课下课程	视频和 PDF 展示正常	通过
7	视频流畅播放	进入视频播放页面	视频播放稳定且流畅	通过
8	视频暂停状态	多次点击视频页面, 能够实现播放与暂停切换	切换正常	通过
9	学习进度展示	用户观看课程视频后, 课程下方展示正确学习率	学习率数字有增长, 且对应视频时长正确	通过

4.4.2 非功能测试

(1) 性能测试

本文采用 JMeter 性能测试工具针对高并发、负载高的场景进行压测，选取森林疗养课程培训系统中所有查接口。通过 JMeter 工具每隔 2 秒为系统加载一个用户，分别测试 200 和 500 名用户并发操作时关键功能查接口的响应时间。性能测试的结果如表 4.15 所示。

表 4.15 性能测试结果

Table 4.15 The performance test results

接口	接口说明	200 并发		500 并发	
		错误率	响应时间	错误率	响应时间
/class/getAllClassPage	查询所有班课	0.11%	0.64s	0.31%	1.61s
/class/getAllClassByTypePage	查询每页班课	0.10%	0.52s	0.26%	1.63s
/class/getClassUnderway	查询进行班课	0.27%	1.35s	0.91%	2.17s
/class/getClassById	根据 id 查班课	0.12%	0.32s	0.45%	1.73s
/class/getStudentStatus	查询学习状态	0.13%	0.25s	0.21%	1.21s
/class/getStudentByName	查询班课学员	0.15%	0.36s	0.24%	1.23s
/course/getAllCourse	查询所有课程	0.17%	0.63s	0.30%	1.33s
/course/getAllCourseByClassId	查询班课课程	0.11%	0.54s	0.39%	1.35s
/course/getCourseUserId	查询课程学员	0.12%	0.72s	0.39%	0.97s
/video/getVideo	查询视频资源	0.18%	0.43s	0.41%	0.85s
/video/getVideoNotCourse	查未绑定视频	0.16%	0.45s	0.42%	1.52s
/pdf/getAllPdf	查询所有 pdf	0.16%	0.52s	0.41%	1.55s
/pdf/getPdfNotCourse	查未绑定 pdf	0.12%	0.37s	0.27%	1.44s
/alipay/getPagePay	查询设备订单	0.12%	0.35s	0.30%	1.50s
/alipay/getAppPagePay	查询软件订单	0.13%	0.44s	0.29%	1.63s
/order-success/getBuyStatus	查询成功订单	0.14%	0.35s	0.31%	1.22s

性能测试结果表明，森林疗养课程培训系统中班课、课程、视频资源、PDF 资源、支付和订单等关键功能模块查接口的错误率和响应时间符合预期，即本系统具备应对用户高并发场景能力，能够满足性能需求。

（2）兼容性测试

森林疗养课程培训系统属于 Web 端系统,应满足市面上主流浏览器兼容性需求。本文分别在 IE、Chrome、Edge、FireFox 以及 Safari 五大浏览器上进行兼容性测试。测试结果如表 4.16 所示。

表 4.16 兼容性测试结果

Table 4.16 The compatibility test results

浏览器	测试结果
IE 浏览器	所有界面布局正常,所有功能可正常使用
Chrome 浏览器	所有界面布局正常,所有功能可正常使用
Edge 浏览器	少许界面排版存在细微变化,所有功能可正常使用
FireFox 浏览器	少许界面排版存在细微变化,所有功能可正常使用
Safari 浏览器	所有界面布局正常,所有功能可正常使用

兼容性测试结果表明,森林疗养课程培训系统能够满足市面上主流浏览器兼容性需求,系统页面可正常展示和交互,兼容性测试符合预期。

4.5 本章小节

本章从系统需求分析、概要设计以及详细设计与实现三个方面详细介绍了森林疗养课程培训系统的研建。首先,对系统进行了需求分析,通过用例图并结合文字描述方式对系统各模块具体功能需求进行了详细阐述。其次,介绍了系统概要设计,包括系统总体架构图、功能模块结构图以及系统数据库表设计,然后通过活动图、类图和时序图方式对关键功能模块的详细设计进行详细说明,并给出系统的实现页面展示,最后对本系统进行了功能性与非功能性两方面测试。

5 总结与展望

本章首先分析了文本视频跨模态检索和森林疗养课程培训系统解决的主要问题，并总结本文基于视频字幕和多空间学习检索模型现有研究和森林疗养课程培训系统研建，同时展望了基于多空间学习检索模型优化或扩展方向。以下是本文总结与展望。

5.1 总结

随着互联网普及和在线视频平台快速发展，大量文本和视频数据不断产生。面对爆炸式增长的多模态信息，人们迫切需要找到有效途径来检索目标内容，T2VR 作为自然语言处理和计算机视觉交叉领域的一项核心任务，受到了广泛关注。在此背景下，本文针对仅构建单个公共空间或多个跨模态公共空间进行特征匹配存在的问题，通过一系列研究和探索，发现目前还没有结合同模态公共空间和融合多空间方面研究工作。与此同时，森林疗养作为绿色可持续发展的林业新模式，不仅为广大人民群众带来健康福祉，同时促进人与自然和谐共生的理念。森林疗养课程培训系统作为一种在线课程培训平台，旨在促进参与森林疗养培训学员对培训课程深入理解和学习，从而提升森林疗养师的培训质量和专业水平。然而，为数不多的现有系统因课程视频繁杂以及检索系统存在局限性，常常导致用户难以高效准确检索到目标课程视频，影响培训质量和效果。基于以上背景，本文设计实现了一个 Web 端的森林疗养课程培训系统。该系统分为学员端和管理员端，不仅能为学员提供友好、实用的系统培训服务，还能管理员提供资源管理、课程管理、班课管理和学员管理等功能模块。同时，通过将 TVRVCML 模型应用于本系统的课程视频检索功能，以缓解用户检索困难问题，显著提升了培训质量和效果。

本文主要研究内容和研究成果，归纳总结如下：

(1) 为捕获和计算查询文本和视频之间相似度，本文提出了一种基于视频字幕和多空间学习的检索模型 TVRVCML，其通过在两类多空间中引入自注意力机制来优化检索性能。首先，该模型通过多个不同种类的文本编码器提取了多种文本特征向量，并与视频向量交互构建出多个跨模态公共空间。与此同时，增加视频字幕文本编码器，借助查询文本向量与视频字幕向量之间交互构建出一个同模态公共空间，发挥跨模态匹配与同模态匹配相结合优势，在两种类型公共空间中分别处理跨模态信息和同模态信息，从而更加全面地建模和计算多种模态特征向量间关系，以提高模型检索性能。此外，在多个公共空间中引入自注意力机制，处理多空间之间权重分配，从而建模不同公共空间关系并处理每个公共空间对于模型整体检索性能的差异性贡献。

(2) 为验证 TVRVCML 模型检索性能，本文选取了在 T2VR 任务中公认的 MSVD、MSR-VTT 和 TGIF 基准数据集，通过在三个数据集上通过与四个先进模型进行对比实验，并选用三个 T2VR 任务中常用评价指标观测模型表现，验证了 TVRVCML 模

型设计的合理性。同时，在 MSVD 数据集上通过构建消融实验，进一步说明了模型创新模块的有效性和贡献度。

(3) 针对林学会森林疗养分会亟需实现在线培训需求，本文采用了 Vue.js 和 Spring Boot 前后端分离的开发模式设计实现了一个 Web 端森林疗养课程培训系统。该系统分为学员端和管理员端，不仅能为学员提供友好、实用的系统培训服务，还能管理员提供资源管理、课程管理、资源管理和学员管理等功能模块。同时，通过将 TVRVCML 模型应用于本系统的课程视频检索业务，以缓解用户检索困难问题。系统不仅能够提高疗养师培训效果和质量，还有助于森林疗养行业的持续发展，推进我国生态文明建设进程。

5.2 展望

本文研究提出的基于视频字幕和多空间学习的 TVRVCML 检索模型，虽然其在实验结果上表现出良好检索性能，但是仍然存在进一步优化空间。

(1) 首先，本文提出的 TVRVCML 模型在查询文本和视频模态特征表示方面使用了多种编码器组合。随着深度神经网络的不断进步，如何选取适合 T2VR 任务的编码器，并将其进行合理搭配组合以捕获更全面地模态信息，可以作为后续深入思考研究方向。

(2) 其次，TVRVCML 模型基于目前 T2VR 任务中主流的公共空间学习方法，公共空间的构建和处理是决定模态匹配质量的关键步骤。本文借助跨模态公共空间和同模态公共空间相结合方法取得良好效果。因此，丰富公共空间的个数、种类并结合，同样也是 T2VR 任务中值得后续研究的方向。

(3) 最后，由于目前 T2VR 检索模型体量通常较大，会出现模型训练困难以及计算负担较重的问题。因此，如何将检索模型轻量化或者设计为端到端框架同样可以作为优化检索性能的一个重要研究方向。

参考文献

- [1] 邓三龙. 森林康养的理论研究与实践[J]. 世界林业研究, 2016, 29(06): 1-6.
- [2] Awad G, Fiscus J, Joy D, et al. Trecvid 2016: Evaluating video search, video event detection, localization, and hyperlinking[C]. TREC Video Retrieval Evaluation (TRECVID), 2016.
- [3] 张志永, 叶兵, 刘立军, et al. 森林疗养发展历程与特征分析及研究展望[J]. 世界林业研究, 2020, 33(04): 7-12.
- [4] 李秀丽. 我国高校慕课建设及课程利用情况调查分析——以中国大学 MOOC 等四大平台为例[J]. 图书馆学研究, 2017, (10): 52-57.
- [5] 王帅国. 学堂在线平台: 以创新推动高等教育数字化升级[J]. 中国高等教育, 2023, (02): 37-42.
- [6] 王帅国. 雨课堂:移动互联网与大数据背景下的智慧教学工具[J]. 现代教育技术, 2017, 27(05): 26-32.
- [7] 牟占生, 董博杰. 基于 MOOC 的混合式学习模式探究——以 Coursera 平台为例[J]. 现代教育技术, 2014, 24(05): 73-80.
- [8] Ueki K, Hirakawa K, Kikuchi K, et al. Waseda_Meisei at TRECVID 2017: Ad-hoc Video Search[C]. TRECVID, 2017.
- [9] Markatopoulou F, Galanopoulos D, Mezaris V, et al. Query and keyframe representations for ad-hoc video search[C]. Proceedings of the 2017 ACM on international conference on multimedia retrieval, 2017.
- [10] Snoek C G, Li X, Xu C, et al. University of Amsterdam and Renmin University at TRECVID 2017: Searching Video, Detecting Events and Describing Video[C]. TRECVID, 2017.
- [11] Habibian A, Mensink T, Snoek C G. Video2vec embeddings recognize events when examples are scarce[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 39(10): 2089-2103.
- [12] Li X, Xu C, Yang G, et al. W2vv++ fully deep learning for ad-hoc video search[C]. Proceedings of the 27th ACM international conference on multimedia, 2019.
- [13] Gabeur V, Sun C, Alahari K, et al. Multi-modal transformer for video retrieval[C]. Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part IV 16, 2020. Springer.
- [14] Wu X, Qian J, Wang T. Text-video retrieval method based on enhanced self-attention and multi-task learning[J]. Multimedia Tools and Applications, 2023, 82(16): 24387-24406.
- [15] Mithun N C, Li J, Metze F, et al. Learning joint embedding with multimodal cues for cross-modal video-text retrieval[C]. Proceedings of the 2018 ACM on international conference on multimedia retrieval, 2018.
- [16] Miech A, Laptev I, Sivic J. Learning a text-video embedding from incomplete and heterogeneous data[J]. arXiv preprint arXiv:180402516, 2018.
- [17] Wray M, Larlus D, Csurka G, et al. Fine-grained action retrieval through multiple parts-of-speech embeddings[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019.
- [18] Chen S, Zhao Y, Jin Q, et al. Fine-grained video-text retrieval with hierarchical graph reasoning[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020.
- [19] Li X, Zhou F, Xu C, et al. Sea: Sentence encoder assembly for video retrieval by textual queries[J]. IEEE Transactions on Multimedia, 2020, 23: 4351-4362.
- [20] Dong J, Li X, Xu C, et al. Dual encoding for video retrieval by text[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(8): 4065-4080.

- [21] Dong J, Wang Y, Chen X, et al. Reading-strategy inspired visual representation learning for text-to-video retrieval[J]. IEEE transactions on circuits and systems for video technology, 2022, 32(8): 5680-5694.
- [22] Dong J, Li X, Snoek C G. Word2visualvec: Image and video to sentence matching by visual feature prediction[J]. arXiv preprint arXiv:160406838, 2016.
- [23] Wu W, Luo H, Fang B, et al. Cap4video: What can auxiliary captions do for text-video retrieval?[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023.
- [24] Dong J, Li X, Xu C, et al. Dual encoding for zero-example video retrieval[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019.
- [25] Hinton G E. Learning distributed representations of concepts[C]. Proceedings of the eighth annual conference of the cognitive science society, 1986. Amherst, MA.
- [26] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:13013781, 2013.
- [27] Pennington J, Socher R, Manning C D. Glove: Global vectors for word representation[C]. Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP), 2014.
- [28] Kenter T, Borisov A, De Rijke M. Siamese cbow: Optimizing word embeddings for sentence representations[J]. arXiv preprint arXiv:160604640, 2016.
- [29] Guthrie D, Allison B, Liu W, et al. A closer look at skip-gram modelling[C]. LREC, 2006.
- [30] Yu Y, Si X, Hu C, et al. A review of recurrent neural networks: LSTM cells and network architectures[J]. Neural computation, 2019, 31(7): 1235-1270.
- [31] Otani M, Nakashima Y, Rahtu E, et al. Uncovering hidden challenges in query-based video moment retrieval[J]. arXiv preprint arXiv:200900325, 2020.
- [32] Chen Z-M, Jin X, Zhao B-R, et al. HCE: hierarchical context embedding for region-based object detection[J]. IEEE Transactions on Image Processing, 2021, 30: 6917-6929.
- [33] Dey R, Salem F M. Gate-variants of gated recurrent unit (GRU) neural networks[C]. 2017 IEEE 60th international midwest symposium on circuits and systems (MWSCAS), 2017. IEEE.
- [34] Fan H, Yang Y. Person tube retrieval via language description[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020.
- [35] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [36] Devlin J, Chang M-W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:181004805, 2018.
- [37] Li L, Gao X, Deng J, et al. Long short-term relation transformer with global gating for video captioning[J]. IEEE Transactions on Image Processing, 2022, 31: 2726-2738.
- [38] Lei J, Li L, Zhou L, et al. Less is more: Clipbert for video-and-language learning via sparse sampling[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021.
- [39] Torabi A, Tandon N, Sigal L. Learning language-visual embedding for movie understanding with natural-language[J]. arXiv preprint arXiv:160908124, 2016.
- [40] Wen L, Li X, Li X, et al. A new transfer learning based on VGG-19 network for fault diagnosis[C]. 2019 IEEE 23rd international conference on computer supported cooperative work in design (CSCWD), 2019. IEEE.

- [41] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:201011929, 2020.
- [42] Yang X, Dong J, Cao Y, et al. Tree-augmented cross-modal encoding for complex-query video retrieval[C]. Proceedings of the 43rd international ACM SIGIR conference on research and development in information retrieval, 2020.
- [43] Yu Y, Kim J, Kim G. A joint sequence fusion model for video question answering and retrieval[C]. Proceedings of the European conference on computer vision (ECCV), 2018.
- [44] Liu Y, Albanie S, Nagrani A, et al. Use what you have: Video retrieval using representations from collaborative experts[J]. arXiv preprint arXiv:190713487, 2019.
- [45] Wang X, Zhu L, Yang Y. T2vlad: global-local sequence alignment for text-video retrieval[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021.
- [46] Faghri F, Fleet D J, Kiros J R, et al. Vse++: Improving visual-semantic embeddings with hard negatives[J]. arXiv preprint arXiv:170705612, 2017.
- [47] Chen D, Dolan W B. Collecting highly parallel data for paraphrase evaluation[C]. Proceedings of the 49th annual meeting of the association for computational linguistics: human language technologies, 2011.
- [48] Xu J, Mei T, Yao T, et al. Msr-vtt: A large video description dataset for bridging video and language[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016.
- [49] Li Y, Song Y, Cao L, et al. TGIF: A new dataset and benchmark on animated GIF description[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016.
- [50] Hu F, Chen A, Wang Z, et al. Lightweight attentional feature fusion: A new baseline for text-to-video retrieval[C]. European conference on computer vision, 2022. Springer.
- [51] 涂荣成, 毛先领, 孔伟杰, et al. 基于 CLIP 生成多事件表示的视频文本检索方法[J]. 计算机研究与发展, 2023, 60(09): 2169-2179.
- [52] Tian K, Cheng Y, Liu Y, et al. Towards efficient and effective text-to-video retrieval with coarse-to-fine visual representation learning. AAAI 2024: 5207-5214
- [53] Hao X, Zhang W, Wu D, et al. Dual alignment unsupervised domain adaptation for video-text retrieval[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 18962-18972.